

目 录

摘 要	I
Abstract	II
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.2.1 在线招聘数据分析研究	2
1.2.2 岗位薪资影响因素与预测研究	2
1.2.3 岗位技能需求与文本分析研究	3
1.3 研究问题与研究内容	3
1.4 本文组织结构	3
2 相关理论与分析方法	5
2.1 招聘岗位数据分析框架	5
2.2 非参数统计分析方法	5
2.2.1 Kruskal - Wallis 检验	5
2.2.2 ϵ^2 效应量	6
2.2.3 Mann - Whitney U 检验	6
2.2.4 Cliff's δ 效应量	6
2.2.5 BH-FDR 多重检验校正	7
2.3 招聘生命周期与样本计划招聘覆盖构建	7
2.4 文本与技能特征表示	8
2.5 薪资预测模型	9
2.6 模型评价指标	10
2.7 SHAP 模型解释	11
3 数据获取与预处理	12
3.1 数据来源与采集范围	12
3.2 数据采集方案	13
3.3 数据存储与原始数据构成	15
3.4 岗位去重与招聘周期整理	17
3.5 字段清洗与语义修复	18
3.6 薪资变量构造	20
3.7 文本与技能特征构建	21
3.8 建模与计划招聘覆盖数据集构建	23
3.9 本章小结	24
4 互联网 IT 实习岗位特征与招聘生命周期覆盖分析	25
4.1 样本总体结构	25
4.2 薪资总体分布	25
4.3 岗位类别特征	27
4.4 城市与企业结构	28
4.5 招聘周期与计划招聘窗口覆盖	29
4.5.1 招聘周期识别与总体特征	29
4.5.2 计划招聘窗口覆盖与薪资分布变化	30
4.6 业务时间维度下的岗位与薪资变化特征	32

4.7 本章小结	34
5 实习岗位薪资影响因素分析	35
5.1 分析方法	35
5.2 岗位类别与薪资	36
5.3 城市、学历与企业属性的薪资差异	37
5.4 企业认证与公司标签	38
5.4.1 企业认证	38
5.4.2 公司标签	39
5.5 招聘生命周期特征与薪资	40
5.6 面议岗位与公开薪资样本的结构对照	41
5.7 多变量中位数回归	41
5.8 薪资影响因素综合分析	43
6 岗位技能特征及其薪资关联分析	45
6.1 技能提取与统计方法	45
6.2 主要技能特征	45
6.3 技能特征与薪资的描述性关联	47
6.4 本章小结	49
7 薪资预测模型构建与结果分析	50
7.1 特征体系与建模前诊断	50
7.2 数据划分与评价指标	51
7.3 模型构建与超参数	53
7.4 模型比较	54
7.5 最终模型结果	55
7.6 分组预测误差分析	56
7.7 本章小结	58
8 模型稳健性、泛化与解释	59
8.1 特征组消融	59
8.2 不同泛化场景下的模型表现	60
8.2.1 随机划分	62
8.2.2 按公司分组划分	62
8.2.3 按发布时间划分的泛化检验	63
8.3 其他稳健性检验	64
8.4 SHAP 模型解释	64
8.4.1 整体特征贡献	66
8.4.2 技能特征的解释强度与方向	66
8.5 本章小结	68
9 研究结果综合讨论	69
9.1 岗位薪资结构与就业方向	69
9.2 技能需求结构与人才培养	69
9.3 企业属性与招聘配置	70
10 总结与展望	71
10.1 主要结论	71
10.2 研究不足与展望	71
参考文献	72

摘 要

以实习僧平台“互联网 IT”菜单下的实习岗位为对象，分析岗位薪资结构、岗位与企业特征的薪资关联、技能需求、招聘时间特征及薪资预测。172,063 条页面记录按岗位编号整理为 17,144 个唯一岗位，其中 14,883 个岗位具有有效明确薪资，2,245 个面议岗位用于薪资披露结构比较。研究完成字段清洗、薪资解析、技能提取和招聘周期整理，并采用非参数检验、中位数回归、树模型比较、特征组消融和 SHAP 解释开展分析。

明确薪资岗位的薪资中位数为 175 元/天，四分位距为 90 元/天，分布呈右偏。岗位方向形成主要薪资层次：人工智能、前端开发、后端开发和移动开发大类的中位数均为 225 元/天，机器学习细分类为 312.5 元/天，运营、客服等职能类岗位多为 150 至 175 元/天。公司认证的整体关联强度 ε^2 为 0.1975，所属行业为 0.1277，高于学历、实习时长和每周到岗要求。Python 和 SQL 覆盖最广，算法、人工智能、前端、后端和数据岗位呈现不同技术栈。招聘周期的计划持续时长中位数为 207 天，较近发布时间队列中人工智能技能的命中率提高至约 14%~18%。

模型比较中，LightGBM 因验证集 MAE 最低被确定为主模型，独立测试集 MAE 为 35.48 元/天、RMSE 为 64.81 元/天、 R^2 为 0.582，与 CatBoost 表现接近。岗位基础、地域和公司特征构成主要预测信息。公司分组测试的五次 MAE 均值为 53.49 元/天，高于随机划分测试结果。SHAP 与福利标签置换结果显示，公司标签簇、岗位类型、技能数量和具体技能共同参与模型预测。

研究将互联网 IT 实习岗位的薪资分层、技能组合、企业属性与招聘时间特征纳入同一分析框架，为学生比较岗位方向和技能准备重点、学校调整专业课程内容、企业参考同类岗位薪资区间提供数据依据。

关键词：实习岗位；薪资影响因素；招聘生命周期；薪资预测；LightGBM；SHAP

Abstract

This study examines IT internship positions in the internet sector listed on the Shixiseng platform, focusing on salary structure, job and company attributes, skill requirements, recruitment characteristics, and salary prediction. A total of 172,063 page records were consolidated into 17,144 unique positions, including 14,883 with valid disclosed salaries and 2,245 negotiable-salary positions used for disclosure analysis. Following data cleaning, salary parsing, skill extraction, and recruitment-period reconstruction, nonparametric tests, median regression, model comparison, feature-group ablation, and SHAP analysis were conducted.

The median daily salary was 175 yuan, with an interquartile range of 90 yuan. Artificial intelligence, front-end, back-end, and mobile development positions each had a median of 225 yuan per day, while the machine-learning subcategory reached 312.5 yuan. Company certification showed the strongest overall association with salary ($\epsilon^2 = 0.1975$), followed by industry ($\epsilon^2 = 0.1277$). Python and SQL were the most prevalent technical skills, while algorithm, artificial intelligence, front-end, back-end, and data positions exhibited distinct skill requirements. The median planned recruitment duration was 207 days, and the prevalence of artificial-intelligence skills in more recent posting cohorts rose to approximately 14%–18%.

LightGBM was selected based on the lowest validation-set MAE, achieving a test MAE of 35.48 yuan per day, an RMSE of 64.81 yuan per day, and an R^2 of 0.582, with performance comparable to CatBoost. Job, regional, and company features provided the main predictive information. Across five company-group splits, the mean MAE was 53.49 yuan per day, higher than under random splitting. SHAP values and welfare-tag permutation results indicated that company tag clusters, job type, skill counts, and specific skills jointly contributed to model predictions.

This study integrates salary stratification, technical skill combinations, company attributes, and recruitment characteristics into a unified analytical framework. The findings provide data-based references for students' career planning and skill preparation, curriculum adjustment in higher education, and salary benchmarking for similar internship positions.

Key words: IT internship position; Salary determinants; Recruitment lifecycle; Salary prediction; LightGBM; SHAP

1 绪论

1.1 研究背景与意义

在线招聘平台汇集了薪资、岗位类别、工作城市、实习要求和公司属性等信息，为观察实习岗位的薪资结构提供了连续而细致的数据来源。相近的互联网 IT 职能在企业类型、城市和任务内容上存在差异，薪资标注也随之分化。围绕这些字段建立统一的岗位样本、变量体系和比较方法，可以识别哪些岗位与企业特征在薪资分布中占据更重要的位置。

伴随招聘平台的普及，在线招聘数据已经成为观察劳动需求的主要数据源之一，岗位数据也具备了批量分析的条件^[1]。招聘信息同时包含岗位类别、地域、实习要求和公司属性等结构化字段，以及岗位描述等文本信息，为岗位结构、技能需求和薪资关系分析提供了数据基础^[2]。已有研究直接使用在线招聘数据刻画用人单位的需求结构与技能缺口，也有研究从技能角度切入，比较不同技能在劳动市场中的需求强度；针对中低技能与初阶岗位的研究还显示，这类岗位的雇主在招聘平台上提出的技能要求往往高度具体^[3]。如何把这些信息整理成可比较、可建模的形式，并在此基础上刻画实习薪资的结构性差异，是本文要解决的问题。

已有薪资影响因素研究主要关注正式雇佣岗位中的学历、经验、行业和地区。实习岗位同时具有短期用工、技能要求集中和页面信息更新频繁的特点，数据整理需要识别重复页面记录，并从岗位描述中区分招聘要求、岗位职责和公司介绍。围绕岗位去重和技能提取建立稳定的数据基础后，岗位、公司和文本信息才能进入同一分析框架。

研究先处理同一岗位重复出现、页面状态变化和技能文本表达不一致的问题，再以唯一岗位开展薪资关联与预测分析。岗位去重减少了重复记录对岗位数量和薪资分布的影响，历史页面信息则保留为招聘时间与字段变化分析的依据。结果描述互联网 IT 实习岗位在职能、企业属性和技能要求上的薪资差异，并呈现模型在跨公司场景下的预测表现。

1.2 国内外研究现状

现有研究围绕在线招聘数据分析、岗位薪资影响因素与预测、招聘文本技能识别逐步展开。前一类研究说明平台职位信息能够转化为劳动需求指标；第二类研究为薪资差异比较和机器学习预测提供变量与评价思路；第三类研究解决岗位描述中技能表达不规

范、上下文混杂的问题。下面据此梳理相关成果，并明确本研究在岗位去重、技能提取与跨公司预测方面的处理重点。

1.2.1 在线招聘数据分析研究

在线招聘信息已成为研究劳动力市场需求的重要数据来源。Acemoglu 等（2022）利用在线职位信息分析人工智能技术与岗位需求之间的关系，展示了招聘数据在识别技术变化及劳动力需求结构方面的应用价值^[4]。Alekseeva 等（2021）进一步从技能需求角度展开研究，利用在线招聘信息考察人工智能技能的市场需求及其相关特征^[5]。上述研究表明，在线招聘数据能够为岗位需求、技术变化和技能结构分析提供较为细致的信息。

在招聘文本处理方面，Khaouja 等（2021）系统梳理了在线招聘广告中的技能识别方法，介绍了技能提取任务、相关技术及评价方式，为招聘文本的结构化处理提供了方法参考^[6]。招聘信息同时包含结构化字段与自然语言描述，不同岗位之间的字段表达和技能名称存在差异，需要通过字段规范化与文本处理形成统一的分析数据。

对于本文研究的互联网 IT 实习岗位，同一岗位可能因搜索分类重叠、分页展示和页面更新而产生多条记录，岗位描述中的技能表达也存在简称、别名及上下文歧义。本文以岗位编号识别唯一岗位，保留历史记录用于招聘周期整理，并结合分层技能词典与上下文匹配规则构建技能特征，为后续薪资关联分析与预测建模提供数据基础。

1.2.2 岗位薪资影响因素与预测研究

围绕在线招聘信息中的薪资影响因素，Lu 等（2025）基于中国大数据人才岗位招聘广告，分析劳动力市场需求及薪资影响因素，为利用岗位属性、技能要求和企业信息开展薪资研究提供了参考^[7]。王辉和曾湘泉（2017）基于中国劳动力市场大数据，考察劳动力紧缺与工资上涨之间的关系，从劳动力供求角度分析工资变化的影响机制^[8]。在薪酬预测与模型解释方面，孙莹等（2024）提出基于集合效用边际贡献学习的可解释薪酬预测算法，为分析薪资预测结果中的特征贡献提供了相关研究思路^[9]。

在预测方法上，LightGBM^[10] 和 CatBoost^[11] 等梯度提升树模型能够刻画结构化特征与薪资之间的非线性关系，SHAP^[12] 则通过特征贡献分解解释模型预测结果。在线招聘数据包含岗位类别、地域、企业属性、技能要求和岗位描述等多种信息，相关特征可以共同用于薪资预测及模型解释。

已有薪资研究主要围绕正式招聘岗位展开，针对互联网 IT 实习岗位的薪资分布、技能要求和企业属性仍有进一步分析的空间。本文以实习僧平台的互联网 IT 实习岗位为对

象，采用非参数检验和中位数回归分析岗位与企业特征的薪资关联，并在统一的数据划分下比较线性模型与集成树模型。进一步通过特征组消融、按公司分组划分和 SHAP 解释，考察不同特征组的预测贡献、模型的跨公司泛化表现及主要预测依据。

1.2.3 岗位技能需求与文本分析研究

在线招聘文本包含岗位职责、任职条件和企业介绍等内容，其中技能要求通常以自然语言形式表达。同一技能可能存在简称、英文名称和不同版本的表述方式，部分短词还具有上下文歧义。Zhang 等（2022）在 SkillSpan 研究中对英语招聘广告中的硬技能和软技能进行识别，为招聘文本的技能实体提取提供了方法参考^[13]。

在中文实习岗位场景中，技能提取还需要区分明确的任职要求与岗位职责中的一般性技术描述。本文采用分层技能词典和上下文匹配规则，优先识别任职要求中的技能表达，并对完整岗位描述进行补充匹配。同时利用预训练中文文本向量构造语义特征，为岗位技能统计和薪资预测提供输入。

1.3 研究问题与研究内容

本文主要回答三个问题：第一，实习僧平台互联网 IT 实习岗位在岗位类型、地域、企业属性、技能需求和招聘生命周期上呈现怎样的样本结构；第二，上述岗位与企业特征和薪资分布之间存在怎样的统计关联；第三，在控制数据泄漏并区分不同泛化场景后，岗位薪资能够达到怎样的预测精度。三类问题分别对应结构描述、薪资关联分析和预测建模，构成从岗位现状刻画到模型验证的研究主线。

研究对象为实习僧平台“互联网 IT”菜单下的实习岗位，预测目标为平台公开薪资区间的中点。岗位发布、薪资标注、企业属性和岗位文本被整理为统一样本，描述统计、关联分析和预测建模均基于同一批唯一岗位。

1.4 本文组织结构

本文共分为 10 章，各章内容安排如下：

第 1 章：绪论。介绍研究背景与意义，梳理在线招聘数据、岗位薪资预测和技能需求分析的相关研究，提出研究问题、研究内容与全文组织结构。

第 2 章：相关理论与分析方法。说明岗位数据的分析单位与变量类型，介绍非参数检验、招聘时间整理、技能与文本表示、回归预测、模型评价和 SHAP 解释方法。

第 3 章：数据获取与预处理。说明数据来源、采集方式、数据存储、岗位去重、字段清洗、薪资变量构造、技能提取和建模数据集的形成过程。

第 4 章：互联网 IT 实习岗位特征与招聘生命周期覆盖分析。描述岗位样本、薪资分布、岗位类别、城市与企业结构，并分析招聘周期、计划招聘窗口和发布时间队列。

第 5 章：实习岗位薪资影响因素分析。比较岗位类别、城市、学历、公司规模、公司性质、行业、认证、福利标签和招聘时间特征与薪资分布的关联，并报告中位数回归结果。

第 6 章：岗位技能特征及其薪资关联分析。统计高频技能及岗位方向的技术栈，比较代表性技能的薪资差异，并检验技能提取结果的稳定性。

第 7 章：薪资预测模型构建与结果分析。构建岗位、地域、公司、技能和文本特征，比较多种回归模型，报告主模型的测试结果和分组误差。

第 8 章：模型稳健性、泛化与解释。开展特征组消融、随机划分、公司分组和发布时间划分检验，并结合 SHAP 和福利标签置换分析模型预测依据。

第 9 章：研究结果综合讨论。从岗位薪资结构、技能需求、人才培养和企业招聘配置三个方面讨论研究结果的实际含义。

第 10 章：总结与展望。归纳岗位薪资结构、技能需求和薪资预测的主要发现，提出数据扩展、技能识别和跨公司预测的后续研究方向。

2 相关理论与分析方法

2.1 招聘岗位数据分析框架

唯一岗位是横截面统计与预测建模的基本单位；招聘生命周期分析以发布时间和投递截止日期形成的招聘周期为单位。前者呈现岗位层面的薪资差异，后者描述业务日期上的招聘计划变化。

岗位信息分为类别属性、多值属性和文本特征。岗位大类、岗位细分类、工作城市、学历要求、公司规模、公司性质、所属行业与公司认证属于类别属性；公司福利标签与岗位类别集合属于多值属性；岗位描述文本转化为技能标识与文本语义向量。多值属性按岗位与取值展开，岗位数量仍以唯一岗位计数。

目标变量为薪资中点（元/天）。该变量呈右偏分布，均值高于中位数，两侧具有长尾，描述部分报告中位数与四分位距，预测部分同时报告 MAE、RMSE 和 R^2 。据此，本文形成由分组检验、招聘周期整理、文本与技能表示、回归预测和模型解释组成的分析框架。

2.2 非参数统计分析方法

薪资中点呈右偏分布并带有长尾，不同分组的样本量与内部离散程度也存在差异。分组比较采用基于秩的非参数检验，并同时报告效应量，以刻画差异的方向、幅度和统计稳定性。多组互斥变量以 ϵ^2 表示整体关联强度，多值命中变量以 Cliff's δ 表示两类岗位的分布差异。

2.2.1 Kruskal - Wallis 检验

对于工作城市、学历要求、实习时长要求、每周到岗要求、公司规模、公司性质、所属行业与公司认证等单值、互斥的类别变量，本文采用 Kruskal-Wallis 检验^[14]比较不同组别的薪资分布。该检验不要求总体服从正态分布，适合本文薪资中点右偏、组间样本量不均衡的情形。其统计量为

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k n_j \bar{R}_j^2 - 3(N+1) \quad (1)$$

式中， N 为参与比较的总样本量， k 为组数， n_i 为第 i 组样本量， $\bar{R}_i$ 为平均秩，并列秩在计算中作修正。岗位大类和岗位细分类允许同一岗位命中多个取值，因此分别构造“命中该类别”和“未命中该类别”两组，以 Mann-Whitney U 检验和 Cliff's δ 衡量分布

差异，再在同一字段内实施 BH-FDR 校正。每组比较均要求两组样本量达到 50 个岗位。

2.2.2 ε^2 效应量

统计显著性反映组间差异的可检出程度， ε^2 和 Cliff's δ 则给出差异的实际幅度。 ε^2 用于比较单值互斥因素内部的整体关联强度，Cliff's δ 用于岗位类别、福利标签和技能等二元命中变量，两类指标分别服务于相应的变量结构。

$$\varepsilon^2 = \frac{H - k + 1}{N - k} \quad (2)$$

式中， H 为式（1）的统计量， k 与 N 的定义与式（1）一致。Kruskal-Wallis 检验的单值互斥因素以 ε^2 报告整体关联强度；岗位大类、岗位细分类、福利标签和技能等命中变量以 Cliff's δ 报告两组分布差异。两类指标分别对应不同的变量结构。

2.2.3 Mann - Whitney U 检验

比较两个独立组的薪资分布位置时，本文采用 Mann-Whitney U 检验^[15]，它同样基于秩，不要求正态性与方差齐性，适用于两组样本量差异较大、分布形态不一致的情形。其统计量为

$$U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 \quad (3)$$

式中， n_1 与 n_2 为两组样本量， R_1 为第一组秩和。该检验用于公司认证的成对比较、福利标签命中比较和技能命中比较，同一因素内的多组成对结果统一进行多重检验校正。

2.2.4 Cliff's δ 效应量

p 值说明两组差异是否可检出，不说明差异的实际量级，因此两组成对比较同时报告 Cliff's δ 效应量^[16]，它刻画两组样本之间的有序优势程度。 δ 的概率定义为

$$\delta = P(X > Y) - P(X < Y) \quad (4)$$

对应的样本形式为

$$\delta = \frac{1}{n_X n_Y} \sum_{i=1}^{n_X} \sum_{j=1}^{n_Y} \text{sgn}(x_i - y_j) \quad (5)$$

式中， x_i 与 y_j 表示两组的薪资取值， n_X 与 n_Y 分别为两组样本量， $\text{sgn}(\cdot)$ 为符号函数。本文按固定阈值判断效应量级： $|\delta| < 0.147$ 为可忽略， $0.147 \leq |\delta| < 0.330$ 为小效应， $0.330 \leq |\delta| < 0.474$ 为中等效应， $|\delta| \geq 0.474$ 为大效应。方向、大小与显著性需同时报告。

2.2.5 BH-FDR 多重检验校正

在同一次分析中同时比较大量假设时，个别偶然显著的结果可能被当作结论，因此本文采用 Benjamini 和 Hochberg（1995）提出的 BH-FDR 方法^[17]，把错误发现的比例控制在预设水平。给定按升序排列的 p 值 $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$ ，判定规则为寻找满足下式的最大序号 i ：

$$p_{(i)} \leq \frac{i}{m} \alpha \quad (6)$$

式中， m 为假设检验个数， p_i 为升序排列后的第 i 个 p 值， α 为显著性水平， k 为满足条件的最大序号；对应的校正结果记为 q 值。公司福利标签、技能和同一因素内的成对比较统一采用 BH-FDR 校正，正文结合 q 值与效应量呈现主要结果。

2.3 招聘生命周期与样本计划招聘覆盖构建

招聘持续时间是劳动力市场研究中的重要时间特征。史珍珍（2017）基于网络招聘数据考察劳动力市场景气对企业岗位空缺持续时间的影响^[18]。本文以页面展示的发布时间和投递截止日期作为招聘周期的业务时间基础。对同一岗位，先将连续页面记录整理为候选发布时间段，再比较相邻发布时间段与上一计划结束日期之间的间隔。新发布时间较上一计划结束日期晚至少 7 个日历天时，单列为新的发布时间段；其余记录合并至当前周期。另以 3、5、7 和 14 天间隔重复计算，用于观察整理结果对间隔设置的变化。

对每个招聘周期，发布时间作为周期开始时间，投递截止日期作为计划结束时间。周期计划持续时长定义为二者的日历日差；相邻周期之间的间隔定义为新周期开始日期与上一周期计划结束日期之差。将招聘周期按业务日期展开后形成日级计划招聘覆盖面板，用于统计样本内不同业务日期的活跃计划周期数量。

生命周期和覆盖指标用于描述样本中计划招聘区间的业务日期结构，并与岗位薪资、岗位类别和技能需求的时间分布进行对照。相关指标共同刻画岗位发布与计划截止日期形成的招聘时间特征。

一条招聘周期的计划长度由开始日期与计划结束日期之差决定，计算方式见式 (7)：

$$D_{ie}^{(f)} = d_{ie}^{(f)} - s_{ie} + 1, \quad D_{ie}^{(0)} = d_{ie}^{(0)} - s_{ie} + 1 \quad (7)$$

式中， s_{ie} 表示岗位 i 的第 e 个招聘周期开始日期； $d_{ie}^{(f)}$ 与 $d_{ie}^{(0)}$ 分别表示末次观测与首次观测得到的计划截止日期； $D_{ie}^{(f)}$ 与 $D_{ie}^{(0)}$ 为相应计算方式下的计划持续时长。末次观测计

算用于生命周期描述，首次观测计算用于补充比较。该时长表示招聘方在页面上设定的计划招聘窗口长度。

同一岗位相邻两条招聘周期之间的间隔定义为新周期开始日期与上一周期结束日期之差，见式 (8)：

$$G_{ie} = s_{ie} - d_{i,e-1} \quad (8)$$

式中，间隔表示相邻发布时间段之间的日历天数，新候选段的开始日期与上一招聘周期的结束日期共同用于判断时间关系。新发布时间落在上一计划窗口内的记录保留为窗口重叠记录。

一条招聘周期在其起止日期之间的每一天都处于活跃计划招聘状态，把全部周期按岗位、招聘周期与活跃日展开即得到日级计划招聘覆盖面板，面板中一行为某岗位某次招聘周期在某一天处于活跃计划招聘状态，只为活跃日生成记录。该面板用于刻画样本内不同业务日期的计划招聘覆盖状态

$$N_t = \sum_{i,e} I(s_{ie} \leq t \leq d_{ie}) \quad (9)$$

$$O_t = \sum_{i,e} I(s_{ie} = t) \quad (10)$$

$$C_t = \sum_{i,e} I(d_{ie} = t) \quad (11)$$

$$\text{ReopenRate}_t = \frac{R_t}{O_t}, \quad R_t = \sum_{i,e>1} I(s_{ie} = t) \quad (12)$$

式 (9) 至式 (12) 中， s_{ie} 与 d_{ie} 分别表示岗位 i 的第 e 个招聘周期开始日与结束日， N_t 表示业务日期 t 处于计划招聘窗口内的招聘周期数， O_t 与 C_t 分别表示当日新增与计划退出的招聘周期数， R_t 表示当日重新开启的招聘周期数。相邻发布时间段关系作为周期整理的辅助记录，用于核对计划窗口变化。

日级计划招聘覆盖序列由样本中岗位的发布时间与投递截止日期重构，用于描述计划招聘窗口在业务日期上的覆盖分布及其随时间的变化特征。

2.4 文本与技能特征表示

技能需求分析将岗位描述中的技能表述映射为可比较的标准条目。技能词典按技能族、技能组和标准技能名三级组织，共包含 145 个标准技能、549 个别名表达和 17 个技

能组；具体技术技能、技术领域、业务能力与办公工具分别统计。Python、数据分析和 Excel 分属不同层级，分层榜单能够保持岗位覆盖规模与业务含义的一致性。

中文预训练文本嵌入模型能够将自然语言转换为稠密向量。Xiao 等（2024）在 C-Pack 研究中介绍了通用中文文本嵌入的相关资源与方法，为中文语义表示提供了参考^[19]。本文采用 BAAI/bge-small-zh-v1.5 对岗位描述生成 512 维句向量，并通过截断奇异值分解压缩为固定维度的文本语义特征。SVD 保留维数设置为待选配置，在训练阶段依据验证集 MAE 确定。

Deerwester 等（1990）在潜在语义分析研究中利用奇异值分解构造低维语义空间，为文本信息的降维表示提供了经典方法依据^[20]。本文采用截断奇异值分解压缩岗位文本向量，其矩阵近似形式为

$$X \approx U_k \Sigma_k V_k^T \quad (13)$$

式中， X 为岗位描述文本的稠密向量矩阵， U_k 、 Σ_k 与 V_k 分别为截断后的左奇异向量、奇异值矩阵和右奇异向量， k 为保留的 SVD 成分数。中文句向量原始输出为 512 维并已完成 L_2 归一化；SVD 保留维数作为待选配置，并依据验证集 MAE 进行选择。技能采用多标签特征，技能列筛选与截断奇异值分解均在训练集完成后应用于验证集和测试集。

2.5 薪资预测模型

各模型超参数均在预设候选集合中以验证集 MAE 选择，以保证模型比较采用统一的选择规则。线性模型为薪资与特征之间的关系提供可比的线性参照，而类别指示列之间高度相关会使普通最小二乘的系数不稳定，因此本文以 L2 正则约束系数，目标函数为

$$\min_{\beta} \sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \|\beta\|_2^2 \quad (14)$$

式中， y_i 为岗位 i 的薪资中点， x_i 为该岗位的特征向量， β 为回归系数向量， λ 为正则强度， n 为样本量。正则强度在候选集合中按验证集平均绝对误差选择。Ridge 在本文中作为线性预测基线，用于与非线性树模型比较。

为刻画非线性关系与特征交互并与梯度提升树对照，本文使用随机森林。该模型对多棵决策树的自助样本分别拟合，再对输出取平均：

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (15)$$

式中, B 为树的数量, $T_b(x)$ 为第 b 棵树对特征向量 x 的预测输出, $\hat{y}$ 为集成后的预测值。特征子集采样比例设为平方根, 树的数量在候选集合中按验证集平均绝对误差确定。随机森林能够刻画非线性关系与变量交互, 本文将其作为袋装树模型与梯度提升树模型进行比较。

CatBoost 与 LightGBM 均由多棵回归树的输出累加形成预测, CatBoost 使用对称树结构和有序提升策略。全部类别字段已编码为指示列, 四个候选模型使用同一输入矩阵; 树深度、学习率与迭代次数在预设集合内依据验证集 MAE 选择。

本文以梯度提升树作为主模型候选, 用多棵回归树的加和拟合薪资与岗位特征之间的非线性关系:

$$\hat{y}_i = \sum_{m=1}^M f_m(x_i), \quad f_m \in F \quad (16)$$

式中, M 为树的数量, f_m 为第 m 棵回归树, F 为回归树函数空间, x_i 为岗位特征向量, $\hat{y}_i$ 为预测日薪。LightGBM 采用基于梯度的单边采样、互斥特征捆绑、直方图分裂和逐叶生长策略, 树数量、学习率和叶子数依据验证集 MAE 确定。

四个模型的超参数均在预先设定的候选范围内, 以验证集平均绝对误差选取。均值预测和中位数预测用于提供参照, Ridge、随机森林、CatBoost 和 LightGBM 的验证表现用于确定主模型。

表 2-1 模型超参数候选范围

模型	候选范围
Ridge	正则强度 $\in \{0.1, 1.0, 10.0, 100.0\}$
随机森林	树的数量固定为 300、特征子集采样比例固定为 sqrt, 最大深度 $\in \{\text{None}, 20\}$ 、叶节点最小样本数 $\in \{1, 5\}$, 共 4 组候选
CatBoost	(深度, 学习率, 迭代次数) $\in \{(6, 0.05, 500), (8, 0.05, 500)\}$
LightGBM	(树的数量, 学习率, 叶子数) $\in \{(400, 0.05, 31), (400, 0.05, 63), (600, 0.03, 31)\}$

技能列的最低频次阈值设置为 50、80、100 和训练集岗位数的 0.5% 四种候选取值; 文本语义表示的 SVD 成分数设置为 16、32 和 64 三种候选取值。各组候选配置均在训练集上拟合, 并以验证集平均绝对误差确定取值。

2.6 模型评价指标

模型的预测误差需要在独立数据上用统一指标衡量, 本文使用平均绝对误差、均方根误差与决定系数三个指标:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (17)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (18)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (19)$$

式中， y_i 为岗位实际薪资中点， $\hat{y}_i$ 为模型预测值， $\bar{y}$ 为实际值均值， n 为评估样本量。 MAE 以元/天表示平均预测偏差，是模型选择的主要指标； RMSE 对较大偏差更敏感， R^2 表示相对于均值基准的解释程度。训练集用于拟合，验证集完成模型和超参数选择，测试集报告锁定配置的正式性能、诊断和解释结果。

2.7 SHAP 模型解释

集成树模型的预测值可以分解为各特征的加性贡献，从而说明模型依据哪些信息做出判断。SHAP 给出的分解形式为

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j \quad (20)$$

式中， $f(x)$ 为模型对样本 x 的预测值， ϕ_0 为基准预测值，表示背景样本上的平均模型输出； ϕ_j 为第 j 个特征对该样本预测值的贡献， p 为特征个数。该分解将单个岗位的预测结果表示为基准预测值与各特征贡献之和。对某一特征而言， $|\phi_j|$ 越大，说明该特征在该岗位预测中的作用越明显； $\phi_j > 0$ 表示该特征使预测薪资高于基准值， $\phi_j < 0$ 则表示其使预测薪资低于基准值。

本文在测试集上计算主模型的 SHAP 值，用于考察岗位、企业、技能和文本特征对预测结果的贡献；对于二值技能特征，进一步统计技能出现时的平均 SHAP 值和平均绝对 SHAP 值，以分别描述其预测方向和贡献强度。统计检验与中位数回归用于比较不同岗位特征下的薪资差异，SHAP 分析用于识别对模型预测贡献较高的特征。

3 数据获取与预处理

3.1 数据来源与采集范围

本文以实习僧平台“互联网 IT”栏目作为岗位采集范围。该栏目按岗位分组展示岗位名称，平台菜单中的分组标题和岗位名称共同构成本文的岗位搜索项。



图 3.1 互联网 IT 岗位菜单

图 3.1 显示，该栏目按照岗位方向组织搜索入口，分组标题及岗位名称共同构成后续采集任务的搜索项。本文据此设置搜索项，并进入相应岗位的招聘详情页采集信息。

采集内容包括岗位名称、岗位分类、薪资标注、工作城市、学历要求、每周到岗要求、实习时长要求、发布时间、投递截止日期、职位描述和岗位标签，以及公司名称、所属行业、公司规模、公司性质等信息。同时保留来源链接和采集时间，用于岗位去重与招聘周期整理。



图 3.2 岗位详情页字段

岗位详情页中与本文采集相关的主要字段位置如图 3.2 所示。薪资、城市、学历、发布时间、投递截止日期和职位描述等信息均直接来自页面展示内容，采集字段与页面信息相对应。

原始数据以一次岗位详情页抓取记录为单位。同一岗位可能因同时出现在多个岗位分组、搜索结果跨页展示，或企业更新岗位信息后再次被抓取而出现多条记录。因此，原始数据既保留岗位和公司的属性信息，也保留链接、采集时间等记录信息。初始数据共包含 172,063 条岗位记录。

本文的岗位数量统计、薪资分布分析和特征比较，均以实习僧平台“互联网 IT”栏目下采集到的岗位记录为分析对象。

3.2 数据采集方案

采集以平台菜单为任务源、以单机多进程方式完成。任务源由互联网 IT 一级菜单下的岗位分组标题与岗位名称构成，每个搜索项对应一个标准化搜索 URL 与可递增的页码参数；采集进程解析列表页中的岗位详情链接，再由详情页完成字段解析与写入。数据采集总体流程见图 3.3。




图 3.3 数据采集流程

采集过程由详情链接规范化、搜索项名称与链接联合去重、任务进度记录和空结果页识别构成。详情页以联合键识别，已抓取页面按状态更新；搜索任务和详情抓取状态实时写入数据库，未完成页在后续运行中继续执行；解析失败页面单独留存处理。链接规范化为岗位唯一键的一致识别提供基础。

为保证同一岗位链接在不同采集任务中的一致识别，详情链接规范化规则见图 3.4。

```

19 TRACKING_PARAMS = frozenset[str]({
20     'pcm', 'from', 'utm_source', 'utm_medium', 'utm_campaign',
21     'utm_term', 'utm_content', 'spm', 'ref', 'referer', 'share_token',
22 })
23
24 # 默认协议（缺失协议时补齐）
25 DEFAULT_SCHEME = 'https'
26
27
28 def normalize_detail_url(value: object) -> str:
29     """规范化岗位详情链接；空值返回空字符串。"""
30     if not isinstance(value, str) or not value.strip():
31         return ''
32     parts = urlsplit(value.strip())
33     kept_query = [(k, v) for k, v in parse_qs(parts.query, keep_blank_values=True)
34                  if k.lower() not in TRACKING_PARAMS]
35     return urlunsplit((
36         (parts.scheme or DEFAULT_SCHEME).lower(),
37         parts.netloc.lower(),
38         parts.path,
39         urlencode(kept_query),
40         ''
41     ))

```

图 3.4 链接规范化规则

岗位详情链接规范化的实现如图 3.4 所示，处理过程统一协议与域名的大小写、完整保留承载岗位身份的路径，并删除页面片段与无业务含义的跟踪参数。处理后，同一详情页在多次抓取中只对应一个规范化链接。

规范化链接与岗位编号的一致性校验结果见图 3.5。

```

236 # 3) 详情链接规范化 + ID-URL 一一对应
237 work[schema.URL_NORM_FIELD] = url_utils.normalize_series(work[schema.URL_FIELD])
238 raw_url_unique = int(work[schema.URL_FIELD].nunique())
239 norm_url_unique = int(work[schema.URL_NORM_FIELD].nunique())
240 unique_intern_id = int(work[schema.ID_FIELD].nunique())
241 id_url_unique_pairs = int(work[[schema.ID_FIELD, schema.URL_NORM_FIELD]]
242                             .drop_duplicates().shape[0])
243 urls_per_id = work.groupby(schema.ID_FIELD)[schema.URL_NORM_FIELD].nunique()
244 ids_per_url = work.groupby(schema.URL_NORM_FIELD)[schema.ID_FIELD].nunique()

```

图 3.5 链接与岗位编号校验

规范化链接与岗位标识一致性校验的实现如图 3.5 所示，以规范化链接与原岗位标识逐一配对计数。17,144 个实体与 17,144 个规范化链接严格一一对应，校验结果支持以岗位标识作为实体去重依据。

多进程岗位采集过程的实际运行界面如图 3.6 所示。



图 3.6 岗位采集界面

图 3.6 呈现两个浏览器实例并行抓取岗位详情页的运行状态。任务进度表和详情进度表记录分页与详情页状态，链接与岗位标识校验完成实体识别，采集结果由多进程任务队列汇总至数据库。

3.3 数据存储与原始数据构成

采集结果存储于 MySQL 关系型数据库，并按功能划分为任务入口表、原始详情表、预处理结果表、任务进度表和详情进度表五类。前两类保存检索任务与岗位详情记录，预处理结果表承载字段整理和变量构造后的分析数据，两类进度表用于支持断点续爬和重复记录核对。

本文以原始详情表导出的数据作为处理起点。原始表保留页面抓取时获得的字段内容，字段本地化、文本整理、缺失处理、岗位去重和变量构造均在派生数据中完成。

原始数据包含 172,063 条岗位记录和 30 个字段。按用途可分为岗位身份、岗位属性、薪资、实习要求、岗位文本、岗位标签、公司属性、时间信息和抓取上下文九类，主要字段及用途见表 3-1。

表 3-1 原始数据字段与用途

字段类别	代表字段	本文用途
岗位身份	实习岗位编号、岗位详情链接	岗位识别与去重核对
岗位基础属性	岗位大类、岗位细分类、工作城市、是否直辖市	岗位结构特征
薪资	薪资中点、薪资下限、薪资上限、薪资区间宽度	薪资中点作为预测目标，其余字段用于描述和稳健性比较
实习要求	学历要求、学历等级、每周到岗要求、每周到岗天数、实习时长要求、实习月数	岗位要求特征
岗位文本	岗位描述字符数、分词数、段落状态、文本岗位方向	技能提取、文本语义表示及辅助特征构造
岗位标签	岗位标签列表、岗位标签数量	标签数量参与建模，标签内容用于关系分析
公司属性	公司名称、公司实体标识、所属行业、公司性质、公司规模、公司标签、公司简介长度、公司介绍图片链接	公司侧特征、公司认证识别和福利标签分析
技术时间	爬取时间、数据创建时间、数据更新时间	版本排序、数据追溯和采集审计
业务时间	发布时间、投递截止日期	招聘计划窗口的开始和结束时间
抓取上下文	来源岗位分类、搜索页码、原始记录编号	重复记录核对和数据整理追溯

字段完整性核对显示，各字段均有记录，但部分字段包含空字符串或纯空格，合计 314,940 处。预处理时将这类取值统一转换为空缺值，便于后续统计和变量构造。

时间信息分为技术时间和业务时间两类。爬取时间、数据创建时间和数据更新时间反映数据采集与存储过程，主要用于版本排序、数据追溯和采集审计。发布时间和投递截止日期反映岗位页面展示的招聘计划时间：发布时间作为计划开始时间，投递截止日期作为计划结束时间。正式分析中的时间特征由这两个业务时间字段构造。

投递截止日期的取值较为集中：全部样本仅出现 337 个不同日期，出现次数最多的 20 个日期覆盖 59.95% 的记录，前 5 个日期覆盖 37.26%；晚于 2026 年 12 月 31 日的远期日期占 10.70%。因此，本文将其理解为招聘方在页面中设定的计划截止时间，并据此构造岗位的计划招聘窗口。岗位空缺持续时间还会受到企业搜寻安排和劳动力市场环境的影响。为展示原始数据的字段形态，图 3.7 和图 3.8 分别给出岗位、薪资、业务时间和公司字段的记录片段。

	岗位标识	岗位名称	搜索分类	工作城市	薪资原文
0	inn_8qiovrcrc3p8e	海外产品实习生	活动运营	深圳	150-250/天
1	inn_dmqqququ6wkxe	游戏自媒体运营实习生	游戏设计师	杭州	150-180/天
2	inn_hycmrswmopuc	【留用实习】海外运营-葡语	产品经理	北京	薪资面议
3	inn_mfghbwghygsu	电视业务部实习生	运营	上海	100/天
4	inn_qryegxuqlbif	数据标注工程师（工程管理优先）	后端开发	北京	150-200/天
5	inn_vihjsmosjlbk	内容实习专员（线上）	产品运营	深圳	50/天

图 3.7 原始岗位与薪资字段

图 3.7 展示了岗位名称、搜索分类、工作城市和薪资原文等字段。同一岗位编号可能在多条记录中出现，反映其不同搜索分类、不同分页结果或不同采集时点下被记录的情况。

技术时间字段用于整理重复记录和识别页面更新顺序。完成岗位去重和实体整理后，正式分析保留发布时间和投递截止日期作为时间变量。

	岗位标识	学历要求	实习时长	发布时间	投递截止日期	公司名称
0	inn_8qiovrcrc3p8e	本科	实习5个月	2026-01-12 16:53	2026-12-30	快手
1	inn_dmqqququ6wkxe	本科	实习6个月	2026-03-17 11:02	2026-04-17	星翡互动
2	inn_hycmrswmopuc	本科	实习1个月	2026-03-16 15:09	2026-06-17	快手
3	inn_mfghbwghygsu	本科	实习3个月	2023-05-08 11:55	2026-06-30	香港TVB控股子公司TVBC
4	inn_qryegxuqlbif	本科	实习3个月	2026-03-18 17:07	2026-04-09	广联达
5	inn_vihjsmosjlbk	不限	实习3个月	2026-03-25 12:13	2026-03-29	麦昱商贸

图 3.8 原始时间与公司字段

图 3.8 展示了与图 3.7 相同记录对应的发布时间、投递截止日期及公司相关字段,这些字段分别用于后续招聘周期整理、岗位特征分析和薪资预测。

3.4 岗位去重与招聘周期整理

同一岗位可能出现在多个搜索分类、不同采集批次或页面更新后的结果中。研究以实习岗位编号识别同一岗位，将多条记录归并为一个唯一岗位。岗位数量、薪资分布、技能统计和薪资预测均以唯一岗位计算；不同时间的页面记录保留为字段变化和招聘周期整理的依据。

原始数据共包含 172,063 条岗位记录。经重复记录合并、字段变化整理和代表记录确定后，形成 17,144 个唯一岗位，作为横截面分析和薪资建模的基本样本。

首先，以实习岗位编号和采集时间识别同一时点的重复记录。原始数据中共有 8 条

此类重复记录，合并后保留 172,055 条有效采集记录。

随后，按采集时间排列同一岗位的多条记录，并比较岗位名称、薪资、工作城市、学历要求、到岗要求、实习时长、岗位标签、岗位描述及公司属性等主要字段。字段内容一致的记录归并保存；存在差异的记录保留其变化顺序，用于核对岗位信息更新情况。

横截面统计和建模以一岗一行的岗位宽表为基础。代表记录优先选择最后一次有效业务状态下字段较完整的记录；完整程度相同时，依次依据数据更新时间、数据创建时间和原始记录顺序确定。同一岗位的历史记录保留为字段变化和招聘周期分析的依据。

岗位发布时间和投递截止日期共同构成页面展示的计划招聘窗口。对于同一岗位的多条记录，先按发布时间整理：发布时间相同的记录归入同一次招聘过程；发布时间发生变化时，再比较新发布时间与上一计划截止日期之间的间隔。

新发布时间晚于上一投递截止日期至少 7 个日历天时，记为新的招聘周期；间隔为 1 至 6 天的记录归入短间隔重开记录；新发布时间落在上一计划窗口内的记录归入时间重叠记录。周期识别分别按 3、5、7 和 14 天间隔计算，正文采用 7 天间隔的结果。

经过上述整理，正式分析数据以 17,144 个唯一岗位为基础。岗位的历史字段变化和招聘时间信息继续用于字段核对、招聘周期分析及计划招聘窗口构造。

3.5 字段清洗与语义修复

字段清洗首先统一字段名称和结构。平台数据中存在中英文混用、同义表述和历史命名，本文将其整理为中文字段名称，并对工作城市、学历要求、公司规模和公司性质等字段建立规范取值。岗位大类、岗位细分类、岗位标签和公司标签等多值字段统一保存为列表，便于后续统计、技能提取和特征构造。

企业认证信息由公司介绍图片链接识别。根据图标文件名与认证类别的对应关系，将图片链接转换为认证标签。该映射覆盖全部非空链接，完成转换后以认证标签参与分析。企业认证属于类别属性；公司标签则记录福利、企业文化等多值信息，两类字段分别处理。

同一岗位在不同采集记录中出现字段差异时，按字段组记录冲突情况，并保留相关记录用于数据核对。冲突记录数及字段分布单独保存，代表记录的取值结合字段完整性和采集顺序确定。

公司属性字段中还发现部分语义异常：字段虽然有值，但内容与字段含义不符。例如，公司规模字段出现地点文本，公司性质字段出现人数区间。本文根据字段取值形态

筛选异常记录，共识别 467 条，其中公司规模和公司性质同时异常 340 条，仅公司性质异常 111 条，仅公司规模异常 16 条。对于能够由同一岗位其他记录确认的字段，采用一致值补充；无法还原的公司性质记为缺失值。

为核对异常来源，本文将 467 条候选记录逐列与数据源记录进行比对，字段内容均保持一致。由此可见，异常来自原始记录中的字段取值，需要在预处理阶段按字段含义进行修复。具体识别规则见图 3.9。

```
126 def classify_company_attribute_slot_anomaly(nature_scale: pd.Series, size_location: pd.Series,
127                                             location_empty: pd.Series) -> pd.Series:
128     """按三类规则判定异常类型：命中「症状但所在地非空」的行返回 NOT_REPAIRABLE（不修复）。"""
129     nature_hit = nature_scale.to_numpy()
130     size_hit = size_location.to_numpy()
131     empty = location_empty.to_numpy()
132     types = np.full(len(nature_scale), '', dtype=object)
133     both = nature_hit & size_hit & empty
134     nature_only = nature_hit & (~size_hit) & empty
135     size_only = (~nature_hit) & size_hit & empty
136     types[both] = FULL_SHIFT
137     types[nature_only] = NATURE_ONLY
138     types[size_only] = SIZE_ONLY
139     types[(nature_hit | size_hit) & (~empty)] = 'NOT_REPAIRABLE'
140     return pd.Series(types, index=nature_scale.index)
```

图 3.9 公司属性异常识别

图 3.9 展示了异常记录的筛选条件：公司性质字段出现人数区间、公司规模字段出现地点文本，或公司所在地缺失。按该规则识别出 467 条候选记录，其中公司规模和公司性质同时异常 340 条，仅公司性质异常 111 条，仅公司规模异常 16 条。

修复时，能够从同一岗位其他记录确认的字段按一致取值补充；缺少可靠依据的公司性质保留为空。修复完成后重新检查，公司规模和公司性质字段均符合预设的取值范围。

	公司	异常类型	性质(前)	规模(前)	所在地(前)	性质(后)	规模(后)	所在地(后)
0	AAA教育	FULL_SHIFT	150-500人	北京	空	缺失	150-500人	北京
1	南昌新东方	NATURE_ONLY	500-2000人	空	空	缺失	500-2000人	缺失
2	议冉会务	SIZE_ONLY	民营企业	上海	空	民营企业	缺失	上海

图 3.10 公司属性异常修复示例

公司属性异常记录修复前后的代表性结果见图 3.10。修复后的公司规模、公司性质和所在地字段可用于后续岗位与公司特征分析。

3.6 薪资变量构造

平台薪资以文本形式展示，可归为区间薪资、单值薪资和面议三类。明确薪资均以元/天为单位，解析后生成薪资下限、薪资上限和薪资中点；单值薪资的上下限取相同数值。

面议岗位共 2,245 个，占全部岗位的 13.10%，保留在岗位结构统计中。薪资分析和预测使用明确薪资岗位。解析后发现 16 条逻辑异常记录，主要表现为上下限倒置或数值异常，单独留档。最终形成 14,883 个有效薪资样本。具体解析规则见图 3.11。

```

81  if any(token in text for token in negotiable_tokens):
82      record[schema.SALARY_NEGOTIABLE_FIELD] = 1
83      record[schema.SALARY_PARSE_STATUS_FIELD] = '面议'
84      records.append(record)
85      continue
86  has_unit = any(token in text for token in unit_tokens)
87  body = text
88  for token in unit_tokens:
89      body = body.replace(token, '')
90  numbers = re.findall(r'\d+(?:\.\d+)?', body)
91  if not numbers or not has_unit:
92      records.append(record)
93      continue
94  values = [float(item) for item in numbers]
95  low, high = (values[0], values[0]) if len(values) == 1 else (values[0], values[1])
96  flags = []
97  if high < low:
98      flags.append('上下限倒置')
99  if low <= 0:
100     flags.append('下限非正数')
101  if high <= 0:
102     flags.append('上限非正数')
103  record.update({schema.SALARY_MIN_FIELD: low, schema.SALARY_MAX_FIELD: high,
104                schema.SALARY_MID_FIELD: (low + high) / 2,
105                schema.SALARY_PARSE_STATUS_FIELD: '已解析',
106                schema.SALARY_ANOMALY_FIELD: ' '.join(flags)})
107  records.append(record)

```

图 3.11 薪资字段解析

图 3.11 展示了薪资字段的处理过程：先识别面议记录，再提取文本中的数值；区间薪资分别生成上下限，单值薪资的上下限取相同数值，最后计算薪资中点。四类典型薪资文本的解析结果见图 3.12。

	形态	薪资原文	下限	上限	中点	解析状态	异常标志
0	区间	120-150/天	120	150	135	已解析	—
1	单值	100/天	100	100	100	已解析	—
2	面议	薪资面议	缺失	缺失	缺失	面议	—
3	异常区间	150-0/天	150	0	75	已解析	上下限倒置；上限非正数

图 3.12 薪资解析示例

图 3.12 展示了区间、单值、面议和逻辑异常四类薪资文本的处理结果。区间薪资生成下限、上限和中点；单值薪资三项数值相同；面议记录的薪资数值为空。

本文以薪资中点作为主要分析和预测目标，即薪资下限与上限的平均值；薪资下限和薪资上限用于稳健性比较。样本构成见表 3-2。

表 3-2 薪资样本构成

处理环节	岗位数
唯一岗位实体	17,144
薪资标注为面议	2,245
明确薪资可解析	14,899
逻辑异常	16
正式薪资样本	14,883

3.7 文本与技能特征构建

岗位描述用于技能提取和文本语义表示。处理时先清除薪资区间、薪资单位和面议等表达，使文本特征聚焦于岗位要求；技术版本号、到岗天数和实习月数等业务数字予以保留。

技能识别优先在“任职要求”“岗位要求”“任职资格”等明确要求段落中进行；未定位到相应标题时，再对完整岗位描述进行补充匹配。明确要求段落匹配到技能的岗位为 8,822 个，全文补充匹配到技能的岗位为 7,556 个；缺少可解析岗位描述的 766 个岗位单独记录。

要求段落命中与全文补充匹配的岗位共同构成技能特征，岗位描述不可解析的记录作为文本状态单列。技能词典按技能族、技能组和标准技能名三级组织，具体技术技能、技术领域、业务能力和办公工具分别统计。

技能词典按技能族、技能组和标准技能名三级组织。技能榜单分为具体技术技能、技术领域、业务能力和办公工具四类，短句匹配结合上下文和排除词进行判断。

岗位描述进入技能和语义特征构造前，先按固定表达识别薪资区间、单位和面议表述。图 3.13 展示清理规则在真实文本上的处理结果。

```
344 def build_model_safe_version(semantic_text: str) -> tuple:
345     """删除直接目标泄漏信息"""
346     if not semantic_text:
347         return '', 0
348     safe = semantic_text
349     hits = 0
350     for _round in range(SALARY_CLEAN_ROUNDS):
351         round_hits = 0
352         for pattern in SALARY_LEAKAGE_PATTERNS:
353             safe, count = pattern.subn(SALARY_REMOVAL_TOKEN, safe)
354             round_hits += count
355         hits += round_hits
356         if round_hits == 0:
357             break
358     safe = re.sub(r'[ \t]{2,}', ' ', safe)
359     safe = re.sub(r'\n{2,}', '\n', safe)
360     return safe.strip(), hits
```

图 3.13 岗位描述薪资清理

图 3.13 展示了薪资文本的识别与清理方式。薪资表达被移出文本，技术版本号、实习月数和每周到岗天数等业务数字保留。

	规范技能	技能族	技能组	命中次数
0	C++	技术技能	编程语言	1
1	OpenCV	技术技能	AI框架	1
2	PyTorch	技术技能	AI框架	1
3	Python	技术技能	编程语言	1
4	TensorFlow	技术技能	AI框架	1
5	模型部署	技术技能	大模型技能	2
6	深度学习	技术技能	AI算法技能	2
7	爬虫	技术技能	数据采集	1
8	计算机视觉	技术技能	AI算法技能	2
9	人工智能	技术领域	技术领域	2

图 3.14 技能规范化结果

图 3.14 展示了技能名称规范化后的结果。每条技能记录包含标准技能名、技能族、技能组和匹配位置。

技能结果按岗位与标准技能名的一对多关系保存。高频技能指示列在建模阶段生成，技能数量和技能组计数等聚合特征同步构造。

3.8 建模与计划招聘覆盖数据集构建

数据整理后形成岗位宽表、招聘周期表和日级计划招聘覆盖面板三类分析数据。岗位宽表用于描述统计和薪资预测，招聘周期表用于生命周期分析，日级面板用于业务日期上的招聘窗口覆盖分析。

岗位宽表包含 17,144 个唯一岗位和 65 个字段。招聘周期表包括 7 天间隔下的 17,146 条周期记录，以及短间隔重开记录纳入后的 17,650 条周期记录。17,146 条周期按起止日期展开后形成 4,690,057 条日级覆盖记录。

薪资建模数据由岗位宽表筛选有效薪资岗位形成，共 14,883 行、69 个字段。特征体系分为岗位基础、地域、公司、技能、文本语义和发布时间位置六部分，见表 3-3。

表 3-3 建模特征组

特征组	内容	说明
A 岗位基础	岗位类别、学历要求、到岗要求、实习时长、岗位描述长度等	岗位自身属性
B 地域	工作城市、是否直辖市等	地域信息
C 公司	公司规模、公司性质、所属行业、公司标签相关字段	企业上下文
D 技能	技能命中与技能数量类特征（44 个高频技能指示列与 12 个技能聚合计数）	由技能抽取结果构造，编码后 56 维
E 文本语义	岗位描述文本的稠密语义表示（降维后）	文本信息，编码后 16 维
发布时间位置扩展特征	发布月份、发布星期	由岗位发布时间构造的发布时间位置特征，共 2 个特征，作为扩展敏感性对照

实际参与建模的原始字段共 35 个，其中数值型字段 23 个、类别型字段 9 个、多值型字段 3 个。编码后，A、B、C 三组共 216 维；技能组增加 56 维；文本语义组增加 16 维；A 至 E 合计为 288 维。加入发布时间位置特征后，模型输入为 290 维。

文本语义特征由清理后的岗位描述生成向量，再压缩为 16 个成分。技能指示列、类别变量编码和文本降维均在训练数据上完成。图 3.15 至图 3.17 给出最终建模数据集的代表性字段片段。

	岗位标识	薪资中点	岗位大类	工作城市	学历要求	实习时长	每周到岗
0	inn_ogamzzh7tqty	150	产品、运营	成都	本科	实习3个月	5天/周
1	inn_vjfebcoh7zrw	120	运营	佛山	本科	实习3个月	5天/周
2	inn_vai6upjffr9p	125	运营	广州	本科	实习3个月	4天/周
3	inn_lqaoiwbiso8	350	产品、运营	北京	本科	实习4个月	5天/周
4	inn_hpce5apykrdr	225	前端开发、后端开发、移动开发	上海	本科	实习6个月	3天/周
5	inn_i9olxr5wcfhq	175	前端开发、后端开发、数据、移动开发	济南	本科	实习6个月	5天/周

图 3.15 建模数据的岗位与地域字段

图 3.15 展示薪资中点、岗位类别、工作城市、学历要求、实习时长和每周到岗要求等岗位与地域字段。该字段组构成岗位基础信息与地域信息的主要来源。

	岗位标识	公司名称	公司规模	公司性质	所属行业	公司认证
0	inn_ogamzzh7tqty	萌想科技（实习僧）	150-500人	民营企业	互联网/游戏/软件	—
1	inn_vjfebcoh7zrw	和美术馆	15-50人	社会团体	公共事业/NGO/政府	—
2	inn_vai6upjfr9p	久邦GOMO	500-2000人	民营企业	互联网/游戏/软件	—
3	inn_lqaoiuwbiso8	字节跳动	2000人以上	民营企业	互联网/游戏/软件	最佳雇主、行业认证
4	inn_hpce5apykrdr	Micro Focus	2000人以上	外资企业	互联网/游戏/软件	—
5	inn_i9olxr5wcfhq	神茶科技	15-50人	民营企业	互联网/游戏/软件	—

图 3.16 建模数据的公司字段

图 3.16 展示公司名称、公司规模、公司性质、所属行业和公司认证等字段。这些变量共同构成企业侧特征，并在后续薪资关联和预测分析中使用。

	岗位标识	skill_Python	skill_SQL	技能计数	描述字符数
0	inn_ogamzzh7tqty	0	0	0	0
1	inn_vjfebcoh7zrw	0	0	0	154
2	inn_vai6upjfr9p	0	0	0	456
3	inn_lqaoiuwbiso8	0	0	0	0
4	inn_hpce5apykrdr	1	0	14	532
5	inn_i9olxr5wcfhq	0	0	6	195

图 3.17 建模数据的技能与文本字段

图 3.17 展示了技能指示列、技能聚合特征和岗位文本长度等字段。三张图采用相同的岗位顺序，呈现建模宽表中的字段组织方式。

3.9 本章小结

本章完成从页面记录到分析数据的整理。172,063 条原始岗位记录经去重形成 17,144 个唯一岗位，其中 14,883 个具有有效明确薪资，面议岗位纳入岗位结构统计。发布时间与投递截止日期形成计划招聘窗口，技能文本按任职要求段落优先的规则提取，岗位职责和公司介绍中的词汇归入全文补充匹配范围。

岗位宽表、招聘周期表和日级计划招聘窗口数据分别承载横截面统计、招聘时间描述和业务日期覆盖分析。岗位、城市、公司、技能和文本字段构成比较分析、回归建模和模型评估的主要信息；采集时间、版本和治理标记保留在数据追溯记录中。

4 互联网 IT 实习岗位特征与招聘生命周期覆盖分析

4.1 样本总体结构

岗位结构分析以 17,144 个唯一岗位为总体，薪资分析与预测使用 14,883 个明确薪资岗位，2,245 个面议岗位用于薪资披露结构比较。技能需求统计以能够定位任职要求等明确段落的 8,822 个岗位为主，另有 766 个岗位因描述文本不可解析而单列。

岗位类别为多值字段，同一岗位可同时属于多个大类或细分类，因此各类别岗位数之和高于总体岗位数。岗位结构统计以 17,144 个唯一岗位计数，薪资分布以 14,883 个明确薪资岗位计算。

技能结果区分“要求段落命中”和“全文补充匹配”两种范围：前者反映企业在任职要求中明确列出的技能，后者用于补充预测模型对岗位文本的覆盖。图 4.1 对应展示总体岗位、明确薪资样本与文本状态之间的关系。




图 4.1 分析样本与技能文本构成

图 4.1 表明，8,822 个岗位能够从明确要求段落提取技能，是第 6 章技能需求统计的主体；766 个文本不可用岗位单列。技能覆盖率、技能薪资比较和模型技能特征据此形成对应的样本范围。

4.2 薪资总体分布

正式薪资样本的描述统计见表 4-1。薪资中位数为 175 元/天，均值为 192.87 元/天，高于中位数；四分位距为 90 元/天，P₁₀ 与 P₉₀ 分别为 110 元/天和 300 元/天。最小值为 1.5 元/天，最大值为 1,750 元/天，整体跨度较大，薪资分布呈明显右偏并具有长尾特征。

表 4-1 薪资中点描述统计

统计量	数值（元/天）
样本量 n	14,883
均值	192.87
标准差	99.27
中位数 (P_{50})	175
IQR	90
P_{10}	110
P_{25}	135
P_{75}	225
P_{90}	300
最小值	1.5
最大值	1,750

薪资分布右偏且具有长尾，因此后文以中位数、四分位距和秩检验描述组间差异。原始薪资中点的中位数和四分位距分别为 175 元/天和 90 元/天；经 1%和 99%分位截断后，两项指标未发生变化。图 4.2 展示了薪资主体集中于中低区间、高薪岗位形成右尾的分布特征。




图 4.2 薪资中点分布

图 4.2 中，P10 为 110 元/天、P90 为 300 元/天，总体中位数为 175 元/天。少量高薪岗位对均值的抬升强于对中位数的影响，因此中位数更适合概括样本的典型薪资水平。

4.3 岗位类别特征

按岗位大类统计后可以观察到较明显的薪资层次，但同一大类内部仍包含不同岗位方向。为进一步观察细分岗位之间的差异，主要岗位细分类的薪资中位数及四分位区间见图 4.3。




图 4.3 岗位细分类薪资中位数与四分位区间

图 4.3 显示岗位细分类的薪资层次比大类更清晰。机器学习的中位数最高，为 312.5 元/天；语音、搜索、推荐、图像和自然语言处理等算法方向多为 275 元/天。运营、客服等职能类细分类多在 150 至 175 元/天，两端相差 100 元/天以上，说明岗位任务方向是薪资分层的重要来源。

4.4 城市与企业结构

工作城市映射至省级行政区后，17,040 个岗位得到单一省级归属，104 个全国、海外或城市信息不完整的岗位单列记录。省域岗位分布见图 4.4。




图 4.4 岗位省域分布

图 4.4 按岗位数分位点着色。上海有 5,293 个岗位，北京有 5,265 个，两地合计占已映射岗位的 61.96%；广东占 13.63%，江苏、浙江和四川构成第二层。该图反映的是平台样本在省域和主要城市的集中格局。

城市薪资比较使用 14,883 个明确薪资岗位。北京有 4,253 个岗位，上海有 4,795 个，两地合计占明确薪资样本的六成以上；深圳、杭州、苏州、南京与武汉构成第二层。主要城市的薪资中位数差距相对有限：无锡为 215 元/天、苏州为 190 元/天、深圳为 181.5 元/天，北京与上海均为 175 元/天。机器学习细分类达到 312.5 元/天，而运营和客服多在 150~175 元/天，岗位细分类两端的中位数差距明显大于主要城市之间的差距。北京四分位距达到 115 元/天，反映出同一城市内部不同岗位与企业层级带来的薪资离散。

企业属性的薪资分层较为清晰。2,000 人以上企业共有 7,290 个岗位，薪资中位数为 190 元/天；500~2,000 人企业为 165 元/天，更小规模区间多为 150 元/天。公司性质方面，民营企业有 10,139 个岗位，中位数为 175 元/天；外资企业有 2,634 个岗位，中位数为 165 元/天；国有企业与社会团体均为 125 元/天。行业方面，电子/通信/硬件为 200 元/天，汽车/机械/制造为 190 元/天，互联网/游戏/软件为 180 元/天，广告/传媒和房产/家居/物业/建筑均为 125 元/天。公司规模、公司性质和所属行业均表现出不同程度的薪资层级差异。

4.5 招聘周期与计划招聘窗口覆盖

岗位页面在不同时间可能出现重复发布、重新开放或延长投递期限等情况，仅依据单次页面记录难以反映岗位完整的招聘持续过程。本文根据同一岗位的历史记录整理招聘周期，并利用开始日期和计划截止日期构建计划招聘窗口，在此基础上分析岗位招聘持续时间、不同岗位类别的覆盖变化以及活跃岗位的薪资分布。

4.5.1 招聘周期识别与总体特征

17,144 个唯一岗位经招聘周期整理后共形成 17,146 条招聘周期，其中 17,131 条具有完整且有效的开始日期和计划截止日期，可继续用于计划招聘窗口分析。17,142 个岗位仅识别出一个招聘周期，仅有 2 个岗位存在多个招聘周期，说明样本中的岗位绝大多数只出现一次连续招聘过程。

不同岗位的招聘持续时间差异较大。有效招聘周期的持续时长中位数为 207 天，四分位距为 314 天，P10 和 P90 分别为 23 天和 810 天，最长达到 1,384 天。由这些统计结果可以看出，多数岗位的招聘持续时间集中在较短和中等区间，但仍存在一部分持续时间较长的岗位，使整体分布出现明显的右偏和长尾。

为检验相邻历史记录之间的时间间隔对招聘周期划分结果的影响，分别采用 3 天、5 天、7 天和 14 天进行比较。当时间间隔由 3 天增加至 14 天时，识别出的重新发布事件由 23 次减少至 0 次，招聘周期数由 17,167 条减少至 17,144 条。不同时间间隔下得到的招聘周期总数变化较小，表明绝大多数岗位的周期划分结果较为稳定。综合重新发布记录的识别情况和周期数量变化，后续分析采用 7 天作为相邻记录的划分间隔。

4.5.2 计划招聘窗口覆盖与薪资分布变化

根据 17,131 条有效招聘周期的开始日期和计划截止日期构建计划招聘窗口，其持续时长分布如图 4.5 所示。图中同时给出了持续时长的频数分布、累计分布以及中位数和主要分位点，可以直观看出不同岗位招聘持续时间的集中区间和长尾情况。




图 4.5 招聘周期计划持续时长

图 4.5 显示，招聘周期持续时长呈明显右偏分布，大量岗位集中在较短和中等持续时间内范围，中位数为 207 天。随着持续时长增加，岗位数量逐步减少，P90 达到 810 天，少量超过 1,000 天的招聘周期形成右侧长尾。不同岗位设置的投递期限存在较大差异，部分岗位在较长时间内保持开放状态。

进一步将每条有效招聘周期按照日期展开，得到 2022 年 6 月 17 日至 2028 年 11 月 22 日共 2,351 天的日级计划招聘窗口数据，累计形成 4,690,057 条岗位—日期记录。在任一日期 t ，仍处于计划招聘窗口内的招聘周期数量记为 N_t 。其最小值为 1，中位数为 1,403，最大值为 16,280。按照岗位大类汇总后的计划招聘窗口覆盖情况如图 4.6 所示。




图 4.6 岗位大类的计划招聘窗口覆盖量

图 4.6 展示了不同岗位大类在各日期上的计划招聘窗口数量变化。岗位大类属于多值字段，同一岗位可能同时归入多个类别，因此各条曲线分别表示相应岗位方向在不同日期仍处于招聘状态的岗位规模。运营、产品和人工智能等类别的覆盖数量相对较高，不同类别的变化还受到岗位发布时间、计划截止日期和招聘持续时间的共同影响。

在计划招聘窗口的基础上，将明确薪资岗位与对应招聘周期连接，并按日期统计仍处于招聘状态岗位的薪资中位数和四分位区间，结果如图 4.7 所示。




图 4.7 活跃岗位薪资中位数与四分位区间

图 4.7 显示，日级活跃岗位薪资中位数主要位于 110~200 元/天之间，全期中位数为 150 元/天，低于岗位实体层面的 175 元/天。出现这一差异的原因在于，岗位实体统计中每个岗位只计算一次，而按日期展开后，招聘持续时间较长的岗位会连续出现在多个日期中，因此不同持续时长的岗位对日级薪资分布产生的影响并不相同。四分位区间也随日期发生变化，说明不同时间段内处于招聘状态的岗位构成存在一定差异。

4.6 业务时间维度下的岗位与薪资变化特征

发布时间队列按页面发布日期划分，用于比较不同时间窗口内的岗位数量、薪资分布和技能命中情况。样本发布时间高度集中于 2026 年，尤其集中在 2026 年 3 月，因此本节按照当前采集样本的时间结构比较各发布时间队列之间的差异。

按自然月统计发布时间队列中的样本岗位数，并以自然季聚合作为敏感性对照，结果见图 4.8。




图 4.8 岗位发布时间队列规模

图 4.8 显示，2026 年 3 月的队列岗位数为 10,093 个，2026 年 1 月至 3 月合计 12,498 个；2023 年 5 月为 804 个，是早期唯一的较大队列；2023 年 6 月至 2025 年 11 月各月的队列岗位数大多在 30~300 个之间；2022 年 6 月至 2023 年 3 月的 7 个月每月不足 30 个岗位。队列规模差异与岗位发布时间分布和采集覆盖范围共同相关。按自然季聚合后共得到 17 个季度窗口，其中 2026 年第一季度为 12,498 个岗位，其余季度均不超过 1,152 个，季度层面的集中程度与月度结果一致。

明确薪资样本按照自然月比较发布时间队列的薪资分布，同时报告中位数和四分位区间，结果见图 4.9。




图 4.9 发布时间队列的薪资分布

图 4.9 显示，2023—2024 年多数月份的薪资中位数为 140~175 元/天，2025 年第四季度至 2026 年第一季度为 165~175 元/天；2026 年第一季度共有 10,413 个岗位，中位数为 175 元/天。各窗口四分位距多在 50~115 元/天，月内离散幅度普遍大于相邻月份中位数的变化。发布时间队列中的薪资变化同时伴随岗位类别和企业构成变化，月份之间未呈现明显的单调薪资梯度。

对技能时间队列分别统计 Python、SQL、人工智能和大模型相关技能的命中率，结果见图 4.10。




图 4.10 发布时间队列的技能需求

图 4.10 显示，Python 命中率在各窗口间存在波动，SQL 在 2025 年末至 2026 年的窗口约为 9%~12%；人工智能由早期约 5%~8% 上升至 2026 年前几个月的 14%~18%，大模型相关技能自 2025 年下半年开始出现，多数窗口为 2%~12%。较近发布时间队列中，人工智能相关技能的命中率明显提高，大模型相关技能也更多出现在较晚的发布时间窗口。结合样本发布时间分布，这一结果反映了本次采集样本内部技能结构随发布时间的变化。

4.7 本章小结

本章从岗位类别、城市和企业属性三个方面比较互联网 IT 实习岗位的结构与薪资分布。人工智能、前端开发、后端开发和移动开发等技术岗位的薪资中位数均为 225 元/天，机器学习细分类达到 312.5 元/天，而运营、客服等职能岗位多在 150~175 元/天。主要城市之间的薪资中位数差距相对有限，公司规模、公司性质和所属行业呈现更清晰的组间分层，岗位方向和企业属性构成样本中较突出的薪资结构差异。

招聘时间分析显示，计划招聘窗口持续时长中位数为 207 天，日级活跃岗位薪资中位数全期为 150 元/天，低于岗位层面的 175 元/天，这一差异与长窗口岗位在多个业务日期重复进入覆盖序列有关。发布时间样本高度集中于 2026 年第一季度，较近发布时间队列中的人工智能技能命中率达到约 14%~18%。各月份内部薪资离散幅度普遍大于相邻月份中位数变化，时间维度结果主要体现当前样本中的发布时间结构、计划招聘窗口和技能构成变化。

5 实习岗位薪资影响因素分析

5.1 分析方法

本章以 14,883 个明确薪资岗位为分析样本，考察岗位属性、城市与企业属性同薪资分布之间的关系。互斥多组变量采用 Kruskal-Wallis 检验并报告 ε^2 ；岗位类别和公司标签等多值变量按“命中—未命中”构造二元比较，采用 Mann-Whitney U 检验、Cliff's δ 和 BH-FDR 校正。二元比较要求命中组与未命中组均不少于 50 个岗位，结果同时报告薪资分布、校正后显著性和效应量。

图 5.1 至图 5.3 展示本章统计分析中使用的核心计算函数，分别对应 Kruskal-Wallis 检验与效应量计算、Mann-Whitney U 检验与 Cliff's δ 计算，以及 BH-FDR 多重检验校正。

```

151 def kruskal_wallis(groups) -> dict:
152     """多组比较: Kruskal-Wallis H + 效应量 epsilon²."""
153     from scipy import stats # noqa: PLC0415
154
155     arrays = [np.asarray(group, dtype='float64') for group in groups if len(group) > 0]
156     if len(arrays) < 2:
157         return {'H统计量': None, 'p值': None, 'epsilon平方': None, '组数': len(arrays)}
158     h_stat, p_value = stats.kruskal(*arrays)
159     total = sum(len(item) for item in arrays)
160     epsilon_sq = ((h_stat - len(arrays) + 1) / (total - len(arrays))) if total > len(arrays) else 0.0
161     return {
162         'H统计量': round(float(h_stat), 6),
163         'p值': float(p_value),
164         'epsilon平方': round(float(max(epsilon_sq, 0.0)), 6),
165         '组数': len(arrays),
166     }

```

图 5.1 Kruskal-Wallis 检验与 ε^2 计算函数

图 5.1 给出 Kruskal-Wallis 检验和效应量 ε^2 计算流程。该计算覆盖工作城市、学历要求、实习时长、每周到岗、公司规模、公司性质、所属行业和公司认证等单值变量，输出组间差异检验结果与整体效应量。

```

183         'median_diff': (round(float(np.median(left) - np.median(right)), 4)
184                         if left.size and right.size else None),
185         "cliff_delta": (round(skill_eda.cliff_delta(left, right), 6)
186                         if left.size and right.size else None),
187         '测试是否达标': '是' if min(left.size, right.size) >= min_group else '否（仅描述）',
188     }
189     if min(left.size, right.size) >= min_group:
190         u_stat, p_value = stats.mannwhitneyu(left, right, alternative='two-sided')
191         row['u_stat'] = float(u_stat)
192         row['p_raw'] = float(p_value)
193     else:
194         row['u_stat'] = None
195         row['p_raw'] = None
196     return row

```

图 5.2 Mann-Whitney U 检验与 Cliff's δ 计算函数

图 5.2 展示了 Mann-Whitney U 检验和 Cliff's δ 的代码实现。对于岗位大类、岗位细分类和公司标签等多值变量，分别按照单个取值是否命中划分两组，并计算两组薪资分布的检验结果与 Cliff's δ 效应量。

```

199 def add_fdr(table: pd.DataFrame, p_column: str = 'p_raw',
200             output_column: str = 'p_adjusted_bh', alpha: float = 0.05) -> pd.DataFrame:
201     """Benjamini-Hochberg FDR 校正 (复用 skill_eda.benjamini_hochberg)"""
202     frame = table.copy()
203     if p_column not in frame.columns:
204         frame[output_column] = None
205         frame['FDR显著'] = '否'
206         return frame
207     mask = frame[p_column].notna()
208     adjusted = pd.Series([None] * len(frame), dtype=object)
209     if mask.any():
210         adjusted.loc[mask] = list[Any](skill_eda.benjamini_hochberg(frame.loc[mask, p_column].to_numpy()))
211     frame[output_column] = pd.to_numeric(adjusted, errors='coerce')
212     frame['FDR显著'] = np.where(frame[output_column].notna() & (frame[output_column] < alpha),
213                                '是', '否')
214     return frame

```

图 5.3 BH-FDR 多重检验校正函数

图 5.3 展示了 BH-FDR 多重检验校正的代码实现。该函数对同一组分析产生的多个 p 值进行统一校正，多值变量的二元比较和互斥变量的成对比较分别在各自检验集合内完成校正，并输出相应的校正结果。

5.2 岗位类别与薪资

岗位大类与岗位细分类均为多值字段，本节分别比较命中与未命中岗位的薪资分布，并结合 Cliff's δ 判断差异幅度。

岗位大类共 12 个取值，其中 10 个在 BH-FDR 校正后仍显著。后端开发的 Cliff's δ 为 0.4203，命中岗位薪资中位数为 225 元/天，未命中岗位为 165 元/天；前端开发、人工智能和移动开发的 δ 分别为 0.4031、0.3714 和 0.3563，均达到中等效应。游戏的 $\delta = -0.0020$ ，技术管理的 $\delta = -0.0228$ ，两者均未通过校正。岗位大类的显著差异主要集中在开发与人工智能方向。

岗位细分类共 87 个取值，其中 78 个达到样本量门槛，73 个在校正后保持显著；14 个达到大效应的取值均集中在算法相关方向。规控算法、自然语言处理算法、推荐算法、SLAM 算法、语音算法、图像算法和搜索算法的 Cliff's δ 均在 0.63 左右，其中规控算法为 0.6389，命中岗位薪资中位数为 275 元/天，未命中岗位为 175 元/天。产品助理的 $\delta = 0.0020$ 。细分类结果进一步表明，不同算法与技术方向之间存在较明显的薪资分布差异。

5.3 城市、学历与企业属性的薪资差异

工作城市、学历要求和企业属性均与岗位薪资存在一定关联，但不同因素对应的薪资差异程度并不相同。城市因素的整体效应量 ε^2 为 0.0899。主要城市中，北京和上海岗位薪资中位数均为 175 元/天，深圳为 181.5 元/天，苏州为 190 元/天，无锡达到 215 元/天。整体来看，主要城市之间的薪资中位数存在一定差异，但幅度相对有限，同一城市内部不同岗位方向和企业类型仍存在较大的薪资差异。

学历要求的 ε^2 为 0.0471，在几类因素中相对较低。硕士岗位共 1,301 个，薪资中位数为 225 元/天；本科岗位数量最多，共 10,459 个，中位数为 175 元/天；大专和学历不限岗位的中位数均为 150 元/天。随着学历要求提高，岗位薪资中位数总体呈上升趋势，但学历与薪资之间的整体关联弱于城市和部分企业属性。

企业属性方面，公司规模、公司性质和所属行业对应的 ε^2 分别为 0.0710、0.0633 和 0.1277。公司规模呈现较明显的薪资层次，2,000 人以上企业的岗位薪资中位数为 190 元/天，500~2,000 人企业为 165 元/天，其余规模区间大多为 150 元/天。公司性质方面，民营企业岗位数量最多，薪资中位数为 175 元/天；外资企业为 165 元/天；国有企业和社会团体均为 125 元/天。所属行业的差异相对更明显，电子/通信/硬件岗位薪资中位数为 200 元/天，汽车/机械/制造为 190 元/天，互联网/游戏/软件为 180 元/天，广告/传媒和房产/家居/物业/建筑均为 125 元/天。




图 5.4 城市、学历与公司规模的薪资中位数

图 5.4 并列展示城市、学历和公司规模三类单值因素的薪资中位数。主要城市之间的差距相对有限；硕士岗位的薪资中位数明显高于本科、大专和学历不限岗位；企业规模方面，2,000 人以上企业整体高于中小规模企业。结合效应量结果，公司所属行业的组间差异最为明显，其次为城市和公司规模，学历要求与公司性质的差异相对较弱。由此可见，岗位薪资并非由单一因素决定，不同岗位方向、企业规模及行业背景共同形成了样本中的薪资分层。

5.4 企业认证与公司标签

企业认证为互斥类别变量，公司标签为高基数多值属性，同一岗位可同时命中多个标签。企业认证采用 Kruskal-Wallis 检验与 ϵ^2 ，公司标签采用命中—未命中比较，并报告 Mann-Whitney U 检验、Cliff's δ 及 BH-FDR 校正结果。

5.4.1 企业认证

企业认证由“最佳雇主类认证”和“行业认证”两个维度组合为四类，分别为无认证、仅行业认证、仅最佳雇主认证和两类认证同时存在。四类岗位的薪资分布及组间差异如图 5.5 所示。




图 5.5 企业认证与薪资分布

图 5.5 显示，公司认证状态与岗位薪资存在较明显的分层。无认证岗位与仅行业认证岗位的薪资分布较为接近，而具有最佳雇主认证的岗位整体薪资水平更高，其中同时具有两类认证的岗位表现最为突出。两两比较结果进一步表明，无认证与仅行业认证之间的差异很小，而涉及最佳雇主认证的比较均表现出更明显的组间差异，说明最佳雇主认证与岗位薪资之间的关联强于单独的行业认证。

各类公司认证的岗位数量及薪资统计结果见表 5-1。

表 5-1 公司认证与薪资分布

公司认证类别	岗位数	薪资中位数（元/天）	IQR
无认证	9,104	150	65
行业认证	460	150	40
最佳雇主	4,542	200	60
两者均有	777	350	75
合计	14,883	—	—

从表 5-1 可以进一步看出，无认证岗位数量最多，共 9,104 个；仅行业认证岗位数量较少，共 460 个，两类岗位的薪资中位数均为 150 元/天。具有最佳雇主认证的岗位薪资中位数提高至 200 元/天，同时具有两类认证的岗位达到 350 元/天。结合图 5.5 的分布和效应量结果，公司认证与薪资的差异主要体现在最佳雇主认证及两类认证同时存在的岗位中。

5.4.2 公司标签

公司标签共整理得到 4,328 个原子标签，单个岗位平均命中约 4 个标签。分别比较各标签命中岗位与未命中岗位的薪资分布，并要求两组样本量均不少于 50。共有 183 个标签满足比较条件，其中 114 个经 BH-FDR 校正后仍具有显著差异。代表性标签的岗位覆盖情况和薪资分布见表 5-2。

表 5-2 代表性公司标签与薪资差异

标签	岗位数	岗位占比	薪资中位数（元/天）	IQR
弹性工作制	771	5.18%	350	75
节日礼品	743	4.99%	350	75
餐饮	732	4.92%	350	75
免费健身设施	731	4.91%	350	75
就近租房补贴	731	4.91%	350	75
有发展前景	716	4.81%	225	35.4
互联网	709	4.76%	225	75
各种福利	642	4.31%	225	75
名企实习	622	4.18%	225	75
快速成长	537	3.61%	175	50
有留用机会	462	3.10%	200	45
人工智能	428	2.88%	190	50

免费健身设施、就近租房补贴、餐饮、节日礼品和弹性工作制的 Cliff's δ 分别为 0.936、0.936、0.934、0.924 和 0.874，对应岗位的薪资中位数均为 350 元/天，未命中岗位约为 165 元/天。五个高效应标签的共现关系见图 5.6。




图 5.6 高效应公司标签共现

图 5.6 显示，免费健身设施、就近租房补贴、餐饮、节日礼品和弹性工作制高度集中于同一批岗位：五项标签交集为 731 个岗位，并集为 784 个岗位，两两最大 Jaccard 相似度为 1.0。因此，单个标签的较大效应量更适合解释为特定高薪企业和岗位群体的共同特征。

5.5 招聘生命周期特征与薪资

岗位薪资与招聘时间的比较以 14,883 个明确薪资岗位为基础。招聘时间由同一岗位的发布时间和投递截止日期整理，结果包括重新发布、短间隔重开和计划招聘窗口持续时间三部分。

相邻发布时间相隔 7 天以上的重新发布岗位有 2 个，薪资中点分别为 90 元/天和 600 元/天。其余 14,881 个单周期岗位的薪资中位数为 175 元/天，四分位距为 90 元/天。重新发布岗位数量较少，单周期岗位构成这一比较中的主要样本。

将相隔 1 至 6 天的短间隔重开记录一并计入后，多周期岗位为 482 个，单周期岗位为 14,401 个。多周期岗位的薪资分布略低于单周期岗位，效应量处于小效应区间。

计划窗口持续时间按 42 天、237 天和 359 天分为四组，共覆盖 14,868 个岗位。Kruskal-Wallis 检验和 Spearman 相关分析均显示，窗口持续时间增加时薪资中位数小幅下降，关联程度较弱。

5.6 面议岗位与公开薪资样本的结构对照

平台中有 2,245 个岗位标注为面议，占全部岗位的 13.10%。本节将面议岗位与公开薪资岗位进行结构对照，考察薪资披露状态在城市、公司属性和学历要求等维度上的分布差异。单值字段按完整类别构造列联表并实施卡方检验；多值字段按命中与未命中构造 2×2 列联表，并进行 BH-FDR 校正。

表 5-3 中的 χ^2 与 p 值对应各单值字段的整体列联表检验，“代表性类别”用于展示差异方向。字段间的结果分别结合整体检验与类别比例进行解释。

表 5-3 面议岗位与公开薪资岗位主要结构差异

特征	代表性类别	面议岗位比例	公开薪资比例	χ^2	p 值
工作城市	北京	48.17%	31.56%	356.48	1.03×10^{-69}
公司规模	2,000 人以上	67.26%	48.98%	348.02	3.27×10^{-71}
公司性质	民营企业	87.35%	68.12%	463.98	4.42×10^{-96}
所属行业	互联网/游戏/软件	77.29%	51.83%	611.52	4.82×10^{-124}
学历要求	本科	76.88%	70.27%	91.38	6.70×10^{-19}

五个单值字段的整体列联表检验均达到显著水平，多值类别经 BH-FDR 校正后共有 17 个取值显著。面议岗位中北京占 48.17%，公开薪资岗位为 31.56%；2,000 人以上企业分别为 67.26% 和 48.98%；民营企业分别为 87.35% 和 68.12%；互联网/游戏/软件行业分别为 77.29% 和 51.83%；本科要求分别为 76.88% 和 70.27%。这些结果表明，面议岗位与公开薪资岗位在城市和企业结构上存在系统性差异。

5.7 多变量中位数回归

在单因素比较基础上，本文采用 Koenker 和 Bassett（1978）提出的分位数回归方法^[21]，以第 50 百分位数对应的中位数回归分析岗位与企业特征对薪资条件中位数的影响。分析使用 14,883 个明确薪资岗位，设计矩阵共 132 列，纳入工作城市、学历要求、每周到岗要求、实习时长要求、公司规模、公司性质、所属行业、公司认证类别、岗位大类集合和岗位细分类集合等变量。

工作城市、学历要求、每周到岗要求、实习时长要求、公司规模、公司性质、所属行业和公司认证类别属于单值互斥变量，以指示列进入模型，并保留样本量最大的取值作为参照类别，分别为上海、本科、5 天/周、实习 3 个月、2,000 人以上、民营企业、互联网/游戏/软件和无认证。岗位大类集合与岗位细分类集合为多值重叠变量，各取值以命中指示列进入模型，系数表示命中与未命中岗位之间的条件中位数差异。

表 5-4 中位数回归系数及 Bootstrap 区间

变量	系数（元/天）	95% bootstrap 区间	方向
公司认证类别 = 两者均有（参照：无认证）	185.83	[182.09, 188.92]	正向
每周到岗要求 = 7 天/周（参照：5 天/周）	87.61	[11.40, 154.95]	正向
工作城市 = 合肥（参照：上海）	-59.07	[-65.10, -49.35]	负向
公司性质 = 国有企业（参照：民营企业）	-40.54	[-44.97, -35.96]	负向
公司认证类别 = 最佳雇主（参照：无认证）	28.23	[24.68, 31.62]	正向
岗位细分类集合 = 人工智能（命中 - 未命中）	23.02	[12.39, 33.55]	正向
岗位大类集合 = 人工智能（命中 - 未命中）	19.94	[15.71, 25.20]	正向
学历要求 = 硕士（参照：本科）	15.80	[10.96, 21.29]	正向

表 5-4 将单因素结果放入同一多变量框架。两类认证同时具备的岗位相对无认证岗位高 185.83 元/天，95% Bootstrap 区间为[182.09, 188.92]；最佳雇主相对无认证高 28.23 元/天；每周到岗 7 天相对 5 天高 87.61 元/天，区间较宽；硕士相对本科高 15.80 元/天。合肥相对上海低 59.07 元/天，国有企业相对民营企业低 40.54 元/天。系数的方向和幅度由各变量的参照类别确定。

为考察同一公司多个岗位的相关性对区间估计的影响，在相同设计矩阵和 3,505 家公司上分别进行岗位级 bootstrap 与公司级 cluster bootstrap，各重复 1,000 次。两种区间均以原始样本的中位数回归系数作为点估计，重抽样单位不同，因此差异主要体现在区间宽度。两类区间的对照见图 5.7。




图 5.7 回归系数的 Bootstrap 区间

图 5.7 比较岗位级与公司级 Bootstrap 区间。12 个代表性系数在两种重抽样下方向一致，公司级区间宽度中位数约为岗位级的 1.89 倍；两类认证同时具备的系数仍为 185.83 元/天，但公司级区间扩大至[2.99, 196.80]。这说明公司内岗位相关性主要影响不确定性范围，少数变量对公司聚类更敏感。

5.8 薪资影响因素综合分析

本章结果按照变量结构分别解释。互斥多组因素中，公司认证的 $\varepsilon^2 = 0.1975$ ，所属行业为 0.1277，工作城市为 0.0899，公司规模和公司性质分别为 0.0710 和 0.0633，学历要求、实习时长和每周到岗要求依次为 0.0471、0.0313 和 0.0171。该组结果显示，企业认证、行业和城市与薪资分布的整体关联相对更明显。

多值岗位类别采用 Cliff's δ 衡量命中与未命中岗位的分布差异。岗位大类中，后端开发和前端开发的 δ 分别为 0.4203 和 0.4031；岗位细分类中，14 个大效应取值集中在算法方向，最大值达到 0.6389。公司标签中的部分高效应取值接近 0.9，但这些标签高度共现，主要反映特定公司与岗位群体的联合特征。 ε^2 与 Cliff's δ 对应不同变量结构，因此综合分析在各自效应量体系内分别归纳。

招聘生命周期特征的效应量 ε^2 较小：计划窗口持续时间四组比较的效应量为 0.008，连续变量的 Spearman 相关系数 $\rho = -0.075$ 接近 0。多变量中位数回归中，企业认证、岗位方向、城市、公司性质和学历要求呈现不同方向与幅度的条件中位数差异；公司级 Bootstrap 扩大了部分变量的区间范围，主要系数方向保持一致。

6 岗位技能特征及其薪资关联分析

6.1 技能提取与统计方法

技能需求统计以能够定位“任职要求”“岗位要求”“任职资格”等明确段落的 8,822 个岗位为主；其余描述文本通过全文补充匹配识别技能，覆盖 7,556 个岗位；766 个岗位的描述文本不可解析。技能按具体技术技能、技术领域、业务能力和办公工具分别统计。

技能与薪资的比较以技能是否命中划分两组，要求命中组与未命中组均不少于 50 个岗位。二元比较采用 Mann-Whitney U 检验，以 Cliff's δ 描述薪资分布差异的方向和幅度，并对同一组技能检验实施 BH-FDR 校正。共有 46 个技能满足样本量条件并进入正式比较。

6.2 主要技能特征

在能够定位明确要求段落的 8,822 个岗位中，对标准化后的具体技术技能进行统计，覆盖数量较高的技能见图 6.1。该统计以岗位为单位，同一技能在单个岗位中重复出现时仅计数一次。




图 6.1 核心技术技能 Top20

图 6.1 显示，Python 和 SQL 的覆盖数量明显高于其他具体技术技能，分别出现在 1,264 个和 870 个岗位中，占样本的 14.33% 和 9.86%。Java、C++ 和 C 分别覆盖 452、411 和 323 个岗位，构成较常见的编程语言需求。Linux、PyTorch、数据可视化、AIGC 和 TensorFlow 等技能也具有一定覆盖规模。整体来看，互联网 IT 实习岗位对编程与数据处理能力的需求最为普遍，同时已经出现较多人工智能开发框架和生成式人工智能相关




图 6.3 岗位细分类与技能命中率

图 6.3 表明，各岗位细分类的技能需求主要集中在数据分析、Excel 和办公软件，其中数据分析在多数运营岗位中的命中率最高，Excel 和办公软件也保持较高覆盖。人工智能、Python、SQL 和 PPT 在部分岗位中具有一定需求，而大模型、Java、C++、机器学习、深度学习、Linux 和 PyTorch 等技术技能的整体命中率相对较低。细分类之间仍存在一定差异：数据运营对数据分析及数据处理技能的需求较突出，产品运营、SEO/SEM 运营和内容运营同样具有较高的数据分析需求；产品助理在原型设计和项目管理等技能上的命中率相对更高。由此可以看出，运营类岗位的技能结构以数据分析和通用办公能力为基础，并随具体岗位职责表现出不同的技能侧重。

6.3 技能特征与薪资的描述性关联

技能薪资比较以具备明确薪资且能够定位要求段落的岗位为样本，共 46 项技能满足两组样本量门槛。表 6-1 选取 14 项代表性技能，覆盖主要技术方向及不同效应等级。

表 6-1 代表性技能与薪资关联

技能	命中岗位数	命中组中位数	未命中组中位数	中位数差	Cliff's δ
多模态	93	325	175	+150	0.636
C++	363	300	175	+125	0.611
C	289	300	175	+125	0.549
TensorFlow	159	275	175	+100	0.588
PyTorch	230	275	175	+100	0.594
Java	379	250	175	+75	0.478
Python	1,111	225	165	+60	0.427
大模型	393	225	175	+50	0.434
SQL	694	225	175	+50	0.361
Linux	237	225	175	+50	0.387
Agent	80	225	175	+50	0.295
Git	112	225	175	+50	0.365
Prompt Engineering	89	225	175	+50	0.346
React	66	200	175	+25	0.232

表 6-1 显示，代表性技能的薪资差异具有较明显的层次。多模态对应的中位数差最大，达到 150 元/天；C++、C、TensorFlow 和 PyTorch 等技术技能的中位数差也较高，均在 100 元/天以上。Java、Python、SQL 和 Linux 的岗位覆盖数量相对较多，其中 Python 和 SQL 分别覆盖 1,111 个和 694 个岗位，中位数差为 60 元/天和 50 元/天。Agent、Prompt Engineering 和 React 等技能的覆盖数量较少，对应的组间差异也相对有限。总体来看，较高的薪资差异主要集中在人工智能框架、算法及 C/C++ 等技术要求较强的岗位。

为考察岗位方向差异对技能薪资比较结果的影响，先计算各技能命中岗位与未命中岗位的整体薪资中位数差，再在相同岗位细分类内部进行比较，并按照各细分类中的技能命中岗位数进行加权汇总。调整前后的结果见图 6.4。




图 6.4 控制岗位细分类后的技能薪资差异

图 6.4 显示, 在考虑岗位细分类后, 多数技术技能对应的薪资中位数差有所扩大。大模型由 50.0 元/天增至 125.0 元/天, Python 由 60.0 元/天增至 122.8 元/天, Java 由 75.0 元/天增至 93.4 元/天; SQL 和 Agent 的变化相对较小, 分别由 50.0 元/天增至 60.2 元/天和 51.9 元/天。Excel 的整体差异为 -10.0 元/天, 在岗位细分类内部重新比较后降至 0。由此可以看出, 不同岗位方向的样本构成会影响技能与薪资之间的表面差异。对于大模型、Python 和 Java 等技能, 在相同岗位方向内比较后, 命中技能岗位与未命中岗位之间的薪资差异反而更加明显。

技能数量与岗位薪资也表现出一定的梯度变化。按照技能命中数量将岗位划分为 0、1、2、3、4 和 5 个及以上六组进行 Kruskal-Wallis 检验, 组间差异的效应量为 $\varepsilon^2 = 0.0966$ 。其中, 2、3 和 4 个技能组三组的薪资中位数均为 175 元/天, 因此在结果展示中合并为“2~4 个技能”。0 个技能岗位的薪资中位数为 150 元/天, 1 个技能为 165 元/天, 2~4 个技能为 175 元/天, 5 个及以上技能达到 225 元/天。5 个及以上技能组包含 2,234 个岗位, 四分位距为 125 元/天。整体上, 随着岗位明确要求的技能数量增加, 薪资中位数逐步提高, 但不同技能数量组之间同时存在岗位类别和技术方向构成上的差异。

为检验技能提取结果在不同文本范围下的一致性, 进一步比较任职要求段落与全文补充匹配的技能统计结果。前者覆盖 8,822 个岗位, 后者覆盖 16,378 个岗位, 两种文本范围共有 144 个共同技能条目。高频技能排序具有较高一致性, Top10 技能中有 8 项重合, Top20 中有 17 项重合, Spearman 排名相关系数为 0.973。Python、SQL 等高频技能以及主要岗位方向对应的技术栈在两种统计范围中的位置基本一致, 说明扩大文本匹配范围主要增加了技能识别数量, 没有明显改变主要技能的整体排序。

6.4 本章小结

本章分析了互联网 IT 实习岗位的技能覆盖及其岗位方向差异。Python 和 SQL 是覆盖范围最广的具体技术技能, Java、C++、Linux 及 PyTorch、TensorFlow 等技能也具有较高需求。不同岗位方向具有较明显的技能组合特征, 运营类岗位更集中于数据分析、Excel 和办公软件, 不同技术岗位则对应各自较集中的开发工具和技术栈。

技能薪资比较表明, 多模态、C++、C、TensorFlow 和 PyTorch 等技能对应的岗位薪资差异较大; 在相同岗位细分类内部比较后, 大模型、Python 和 Java 等技能的差异进一步扩大, 不同技能数量组之间的效应量为 $\varepsilon^2 = 0.0966$ 。两种文本范围下的 Top20 技能有 17 项重合, Spearman 排名相关系数为 0.973, 主要技能排序保持较高一致性。

7 薪资预测模型构建与结果分析

7.1 特征体系与建模前诊断

本章以 14,883 个具有有效明确薪资的岗位为建模样本，完成特征诊断、数据划分、候选模型比较、主模型确定与独立测试。整体建模与评估过程见图 7.1。




图 7.1 薪资预测模型构建与评估流程

预测目标为岗位薪资中点，单位为元/天。模型输入由岗位基础、地域、公司、技能和文本语义五组主体特征组成，并加入发布时间位置特征。A 组为岗位基础特征，包括岗位类别、学历要求、实习时长、到岗要求和岗位描述长度等；B 组为地域特征，包括工作城市和地域标识；C 组为公司特征，包括公司规模、公司性质、所属行业、公司认证和公司标签相关字段；D 组为技能特征，包括高频技能指示变量和技能数量类特征；E 组为岗位描述的文本语义表示。

A、B、C 三组编码后共 216 维；D 组为 56 维，其中 44 维为高频技能指示列、12 维为技能聚合计数；E 组经截断奇异值分解后保留 16 维。五组主体特征合计 288 维，加入发布月份和发布星期两个发布时间位置字段后为 290 维。

建模前对候选特征进行可得性、缺失、冗余、低频取值和数据治理属性检查。公司规模相关数值字段与岗位描述长度字段存在较强冗余，正式模型保留公司规模等级和岗位描述字符数；近常量字段、发布时点不可得的版本字段及数据治理过程字段不进入模型。数值特征以训练集统计量进行中位数填补并设置缺失指示列，训练集中频次低于 20 的类别归入“其他”。公司标签、技能列和文本语义特征均在训练集完成筛选与降维。

字段诊断共移出 19 个候选特征，包括 3 个版本类特征、4 个连续数值冗余特征、2 个近常量特征和 10 个数据治理字段。最终建模特征由筛选后的字段及其编码结果构成。

技能需求统计以 8,822 个明确要求段落为基础。预测模型的技能特征在此基础上加入全文补充匹配，共覆盖 16,378 个岗位，分别呈现企业明确提出的技能需求和岗位文本中的技能信息。

7.2 数据划分与评价指标

薪资建模样本共 14,883 个岗位。为保持不同薪资水平样本在各数据集中的分布一致性，按照薪资中点的十分位进行分层随机划分，其中训练集、验证集和测试集分别占 70%、15% 和 15%，对应 10,418、2,232 和 2,233 个岗位。三类数据集的薪资中位数均为 175 元/天，四分位距均为 90 元/天，岗位描述长度、技能数量及主要岗位结构也较为接近，具体分布见表 7-1。

表 7-1 训练集、验证集与测试集基本分布对照

指标	训练集	验证集	测试集
样本量	10,418	2,232	2,233
薪资中位数（元/天）	175	175	175
薪资 IQR（元/天）	90	90	90
平均技能数	2.20	2.26	2.14
岗位描述字符数中位数	335	326	332
一线城市占比	73.25%	73.61%	73.89%
人工智能岗位占比	21.66%	22.63%	22.35%

表 7-1 表明，三个数据集在薪资分布和主要样本特征上保持较高一致性，分层随机划分没有造成明显的样本结构偏移。训练集用于模型参数拟合，验证集用于模型选择、超参数调整和特征配置，测试集仅在模型及参数确定后用于最终性能评价。

模型评价以平均绝对误差 MAE 为主要指标，并同时报告均方根误差 RMSE 和决定系

数 R^2 。MAE 直接反映预测薪资与真实薪资之间的平均绝对偏差；RMSE 对较大的预测误差赋予更高权重，可补充观察模型对极端误差的敏感程度； R^2 用于衡量模型对薪资变化的解释程度。后续模型比较和参数选择主要依据验证集 MAE，测试集结果不参与模型选择过程。

数据划分的实现过程见图 7.2。程序首先按照薪资分位构造分层变量，再依次划分训练集、验证集和测试集，并固定随机种子以保证实验结果可以重复。

```

46 def build_splits(model_frame: pd.DataFrame, random_state: int = SPLIT_RANDOM_STATE,
47                 n_bins: int = SPLIT_BINS) -> pd.DataFrame:
48     """按薪资中点分箱分层划分 train/validation/test (不写入目标值)。"""
49     salary = model_frame[schema.SALARY_MID_FIELD].to_numpy()
50     bins = pd.qcut(pd.Series(salary), q=n_bins, labels=False, duplicates='drop')
51     stratify = bins.fillna(0).astype(int).to_numpy()
52     job_ids = model_frame[schema.ID_FIELD].to_numpy()
53     split = np.empty(len(job_ids), dtype=object)
54
55     holder = StratifiedShuffleSplit(n_splits=1, test_size=SPLIT_RATIOS[1] + SPLIT_RATIOS[2],
56                                   random_state=random_state)
57     train_index, rest_index = next(holder.split(job_ids.reshape(-1, 1), stratify))
58     split[train_index] = 'train'
59     holder2 = StratifiedShuffleSplit(
60         n_splits=1, test_size=SPLIT_RATIOS[2] / (SPLIT_RATIOS[1] + SPLIT_RATIOS[2]),
61         random_state=random_state)
62     valid_rel, test_rel = next(holder2.split(job_ids[rest_index].reshape(-1, 1),
63                                             stratify[rest_index]))
64     split[rest_index[valid_rel]] = 'validation'
65     split[rest_index[test_rel]] = 'test'
66     return pd.DataFrame({schema.ID_FIELD: job_ids, 'split': split})

```

图 7.2 训练集、验证集与测试集划分核心代码

模型训练过程中，数据预处理同样严格区分训练集、验证集和测试集。数值变量填补、类别变量编码、技能特征筛选以及文本特征降维等步骤均只在训练集上学习参数，再使用已经确定的变换处理验证集和测试集，具体实现顺序见图 7.3。

```

507 assembler = model_training.SalaryFeatureAssembler(
508     numeric_columns, categorical_columns, model_training.MULTI_VALUE_COLUMNS,
509     skill_threshold=threshold, text_dim=text_dim, scale_numeric=scale)
510 assembler.fit(train_frame, skill_map, text_for(train_frame))
511 result = (assembler,
512           assembler.transform(train_frame, skill_map, text_for(train_frame)),
513           assembler.transform(valid_frame, skill_map, text_for(valid_frame)),
514           assembler.transform(test_frame, skill_map, text_for(test_frame)))
515 assemble_cache[cache_key] = result

```

图 7.3 训练集拟合与验证/测试集变换核心代码

这种处理方式使三个数据集沿用相同的特征转换规则，同时避免验证集和测试集信息提前进入模型训练过程，为后续模型比较提供一致的数据基础。

7.3 模型构建与超参数

本文选取 Ridge、随机森林、CatBoost 和 LightGBM 作为候选模型，并设置均值预测和中位数预测作为常数基线。各模型使用相同的数据划分和特征体系，其中 Ridge 对数值特征进行标准化处理，随机森林、CatBoost 和 LightGBM 直接使用原始数值特征。模型首先在训练集上拟合并利用验证集完成参数与特征配置选择，确定最终方案后合并训练集和验证集重新训练，并在测试集上进行最终评价。

技能特征首先根据训练集中的出现频次进行筛选。最低频次分别设置为 50、80、100 和训练集样本量的 0.5%（约 52），对应验证集 MAE 分别为 37.07、36.82、36.81 和 36.87 元/天。最低频次为 100 时验证集 MAE 最低，因此最终保留训练集中出现次数不少于 100 的 44 个高频技能。在此基础上增加 12 个技能组聚合计数特征，技能特征共 56 维。

文本语义特征采用截断奇异值分解进行降维，分别比较 16、32 和 64 个成分。三种设置对应的验证集 MAE 分别为 37.90、38.58 和 39.40 元/天，其中 16 维结果最优，因此最终保留 16 个文本语义特征。技能筛选和文本语义降维的实现过程见图 7.4。

```

154         for column in spec.multi_value_columns:
155             exploded = frame[column].explode().dropna().astype(str)
156             spec.multi_value_levels[column] = exploded.value_counts().head(
157                 spec.top_multi_values).index.tolist()
158         counts = {}
159         for job_id in frame[schema.ID_FIELD]:
160             for skill in skill_map.get(job_id, ()):
161                 counts[skill] = counts.get(skill, 0) + 1
162         spec.skill_columns = sorted(skill for skill, count in counts.items()
163                                     if count >= spec.skill_threshold)
164         if spec.text_dim > 0:
165             matrix = self._text_slice(frame, text_matrix)
166             usable = np.abs(matrix).sum(axis=1) > 0
167             if usable.sum() >= spec.text_dim + 1:
168                 reducer = TruncatedSVD(n_components=spec.text_dim, random_state=SPLIT_RANDOM_STATE)
169                 reducer.fit(matrix[usable])
170                 spec.text_mean = reducer.mean_.tolist() if hasattr(reducer, 'mean_') else []
171                 spec.text_components = reducer.components_.tolist()
172         if spec.scale_numeric and spec.numeric_columns:
173             dense = self._numeric_dense(frame)
174             spec.numeric_mean = dense.mean(axis=0).tolist()
175             spec.numeric_std = np.where(dense.std(axis=0) == 0, 1.0, dense.std(axis=0)).tolist()
176         return self

```

图 7.4 技能特征筛选与文本语义降维代码

图 7.4 展示了技能特征和文本语义特征的训练过程。技能出现频次仅在训练集上统计，并根据确定的阈值筛选高频技能；文本向量的降维模型同样只在训练集上拟合，再用于验证集和测试集转换，从而保证三个数据集使用一致的特征构造规则。

最终模型输入由五组特征构成。岗位基础特征、地域特征和公司特征编码后共 216

维，技能特征为 56 维，文本语义特征为 16 维，五组主体特征合计 288 维；进一步加入发布时间位置的 2 个扩展特征后，最终输入维度为 290。各特征块的拼接过程见图 7.5。

```
178 # ---- 变换 ----
179 def transform(self, frame: pd.DataFrame, skill_map: dict,
180               text_matrix: np.ndarray | None = None) -> sparse.csr_matrix:
181     spec = self.schema
182     blocks = [sparse.csr_matrix(self._numeric_dense(frame))]
183     for column in spec.categorical_columns:
184         blocks.append(self._one_hot_categorical(frame, column))
185     for column in spec.multi_value_columns:
186         blocks.append(self._one_hot_multi(frame, column))
187     if spec.skill_columns:
188         blocks.append(self._one_hot_skill(frame, skill_map))
189     if spec.text_dim > 0 and spec.text_components:
190         blocks.append(sparse.csr_matrix(self._text_reduced(frame, text_matrix)))
191     return sparse.hstack(blocks, format='csr')
```

图 7.5 A—E 特征块拼接代码

图 7.5 展示了各特征块按照统一岗位顺序进行拼接的过程。主体特征矩阵由岗位基础、地域、公司、技能和文本语义五部分组成，扩展模型在此基础上加入发布时间位置特征，形成后续各候选模型使用的最终输入矩阵。

7.4 模型比较

各候选模型在同一验证集上的性能见表 7-2，按验证集 MAE 从低到高排列。

表 7-2 验证集模型性能

模型	主要超参数	validation MAE	validation RMSE	validation R ²
LightGBM	n_estimators = 400, learning_rate = 0.05, num_leaves = 63 depth = 8,	36.04	69.97	0.589
CatBoost	learning_rate = 0.05, iterations = 500	36.87	68.68	0.603
RandomForest	n_estimators = 300, max_features = sqrt	38.15	73.75	0.543
Ridge	alpha = 10.0	45.31	85.69	0.383
Dummy (中位数)	—	61.73	110.79	-0.032
Dummy (均值)	—	65.41	109.09	≈0

候选模型比较结果显示，LightGBM 的验证集 MAE 为 36.04 元/天，在各候选模型中最低；CatBoost 的验证集 RMSE 为 68.68 元/天，R² 为 0.603，在这两项指标上表现更好。由于本文以验证集 MAE 作为模型选择标准，因此确定 LightGBM 为主模型。两种梯度提升树模型的整体预测性能较为接近。

综合三项评价指标，LightGBM 和 CatBoost 的预测表现优于随机森林、Ridge 和常数基线。其中 LightGBM 的验证集 MAE 最低，因此确定为后续预测分析的主要模型，CatBoost 保留用于模型间结果比较。上述四类候选模型按照统一接口完成构建，并分别载入参数选择阶段确定的配置，其具体实现见图 7.6。

```

324     if model_key == 'Dummy':
325         return DummyRegressor(strategy='mean')
326     if model_key == 'Ridge':
327         return Ridge(alpha=params.get('alpha', 1.0), random_state=random_state)
328     if model_key == 'RandomForest':
329         return RandomForestRegressor(
330             n_estimators=params.get('n_estimators', 300),
331             max_depth=params.get('max_depth'),
332             min_samples_leaf=params.get('min_samples_leaf', 1),
333             max_features=params.get('max_features', 'sqrt'),
334             n_jobs=-1, random_state=random_state)
335     if model_key == 'CatBoost':
336         from catboost import CatBoostRegressor # noqa: PLC0415
337         return CatBoostRegressor(
338             depth=params.get('depth', 6), learning_rate=params.get('learning_rate', 0.05),
339             iterations=params.get('iterations', 500), random_seed=random_state,
340             verbose=0, allow_writing_files=False)
341     if model_key == 'LightGBM':
342         from lightgbm import LGBMRegressor # noqa: PLC0415
343         return LGBMRegressor(
344             n_estimators=params.get('n_estimators', 400),
345             learning_rate=params.get('learning_rate', 0.05),
346             num_leaves=params.get('num_leaves', 31), max_depth=params.get('max_depth', -1),
347             random_state=random_state, verbose=-1, n_jobs=-1)
348     raise ValueError(f'未知模型: {model_key}')

```


图 7.6 候选回归模型与超参数配置核心代码

图 7.6 展示了 Ridge、随机森林、CatBoost 和 LightGBM 的模型构建过程。四类模型使用相同的输入特征，在各自确定的参数配置下进行训练，使表 7-2 中的性能差异能够直接反映不同模型对当前薪资预测任务的适应程度。

7.5 最终模型结果

根据验证集比较结果，最终采用 LightGBM 进行薪资预测。模型和参数确定后，将训练集与验证集合并重新训练，得到测试集 MAE 为 35.48 元/天、RMSE 为 64.81 元/天、 R^2 为 0.582。与验证集的 MAE 36.04 元/天、RMSE 69.97 元/天和 R^2 相比，两组评价指标处于相近水平。

为进一步观察模型预测值与真实薪资之间的对应关系，将测试样本的真实薪资和预测薪资绘制为散点分布，结果见图 7.7。



最终主模型在测试集上的真实薪资中点与预测薪资中点对照

图 7.7 LightGBM 测试集真实薪资与预测薪资对比

图 7.7 显示，测试样本主要集中在中低薪资区间，该区域的预测结果整体分布在 $y = x$ 参考线附近。随着真实薪资提高，样本数量明显减少，预测值的离散程度逐渐增大。结合测试集整体评价指标可以看出，模型对主体薪资区间的预测较为集中，高薪岗位则表现出更大的预测偏差。

7.6 分组预测误差分析

测试集总体指标能够反映模型的平均预测水平，但不同薪资区间和岗位方向的误差分布仍存在差异。首先按照真实薪资的四分位数将测试样本划分为四组，分界点分别为 135、175 和 225 元/天，并分别计算 MAE 和 nMAE，不同薪资组的误差结果见图 7.8。




图 7.8 薪资分组预测误差

图 7.8 显示，模型误差随岗位薪资水平和岗位方向发生变化。最高薪资四分位组的 MAE 为 63.36 元/天，绝对预测误差较大；最低薪资四分位组的 nMAE 为 0.2953，相对误差较高。不同薪资区间需要采用不同角度评价预测效果，高薪岗位应关注绝对偏差，低薪岗位则应同时考虑误差相对于实际薪资的比例。

薪资区间之外，不同岗位方向的样本规模、薪资水平和特征结构也存在差异。进一步按照岗位大类统计测试集的预测结果，以比较模型在不同岗位方向上的误差表现，结果见表 7-3。

表 7-3 按岗位大类分组的预测误差

分组	n	MAE (元/天)	RMSE (元/天)
产品	933	29.78	44.01
运营	1,493	29.82	43.77
游戏	120	32.25	41.04
技术管理	90	32.52	44.46
客服	164	32.83	58.05
数据	437	49.85	105.34
人工智能	499	55.29	109.88
测试	205	56.11	113.90
前端开发	141	56.22	107.57
后端开发	363	57.09	111.56
运维/技术支持	250	57.33	130.94
移动开发	237	60.21	133.55

产品和运营岗位的 MAE 均在 30 元/天左右，整体误差相对较低；数据岗位的 MAE 为 49.85 元/天，人工智能、测试、前端开发、后端开发和运维技术支持等技术岗位的误差进一步增大，其中移动开发的 MAE 达到 60.21 元/天。结合图 7.8 的薪资分组结果，较大的预测误差主要出现在高薪样本以及部分技术岗位中。

7.7 本章小结

本章完成了薪资预测的数据划分、特征构建、参数选择和候选模型比较。LightGBM 的验证集 MAE 为 36.04 元/天，在候选模型中最低，因此作为最终预测模型。重新训练后，测试集 MAE 为 35.48 元/天、RMSE 为 64.81 元/天、 R^2 为 0.582，验证集与测试集的整体表现较为接近。

分组结果显示，最高薪资四分位组的绝对预测误差最大，最低薪资四分位组的相对误差较高；按岗位方向比较，产品和运营岗位的预测误差较低，人工智能、开发和运维等技术岗位的误差相对更高。

8 模型稳健性、泛化与解释

8.1 特征组消融

为比较不同类型特征对薪资预测结果的影响，固定数据划分、LightGBM 参数和随机种子，仅改变参与建模的特征组。首先使用岗位基础、地域和公司特征（A+B+C），随后依次加入技能特征、文本语义特征以及发布时间位置特征，共形成五组配置。各配置在验证集和测试集上的结果见表 8-1。

表 8-1 特征组消融结果

配置	特征维度	validation MAE	validation RMSE	validation R^2	test MAE	test RMSE	test R^2
A+B+C	216	36.45	71.88	0.566	34.71	63.65	0.597
A+B+C+D	272	36.49	71.45	0.571	35.46	64.69	0.584
A+B+C+E	232	36.51	71.22	0.574	36.22	66.20	0.564
A+B+C+D+E	288	36.04	69.97	0.589	36.00	66.30	0.563
A+B+C+D+E+发布 时间位置	290	36.13	69.77	0.591	36.40	66.95	0.554

表 8-1 显示，仅使用岗位基础、地域和公司特征时，验证集 MAE 为 36.45 元/天，测试集 MAE 为 34.71 元/天。单独加入技能特征后，验证集 MAE 为 36.49 元/天；单独加入文本语义特征后为 36.51 元/天。技能与文本语义同时加入后，验证集 MAE 降至 36.04 元/天；继续加入发布时间位置特征后为 36.13 元/天。五组配置的验证集 MAE 均集中在 36 元/天左右，整体差距较小。

进一步采用配对 Bootstrap 比较新增特征前后的 MAE 变化。技能特征单独加入后，验证集和测试集的 MAE 增量分别为 -0.04 和 -0.74 元/天；文本语义特征对应的增量分别为 -0.06 和 -1.51 元/天；技能与文本语义同时加入后分别为 +0.41 和 -1.28 元/天。发布时间位置加入完整模型后，验证集 MAE 由 36.04 元/天变为 36.13 元/天，测试集由 36.00 元/天变为 36.40 元/天。总体来看，岗位基础、地域和公司属性已经包含较多薪资预测信息，技能和文本语义特征对整体误差的改善幅度相对有限。

为比较不同特征组加入后模型误差的变化，将各配置在验证集和测试集上的 MAE 进行并列展示，结果见图 8.1。




图 8.1 特征组消融的预测误差

图 8.1 结果显示，岗位基础、地域和公司属性已经包含较多有效预测信息。完整特征配置在验证集上的 MAE 最低，为 36.04 元/天，但在测试集上，A+B+C 基础配置的 MAE 为 34.71 元/天，低于完整配置的 36.00 元/天。技能和文本语义特征能够补充岗位描述信息，其对整体预测误差的改善幅度有限，不同配置在验证集和测试集上的表现也存在差异。

五组特征配置在程序中的组合关系见图 8.2，其中 A、B、C、D、E 分别对应岗位基础、地域、公司、技能和文本语义特征。

```

32  ABLATION_CONFIGS = {
33      'Base': ('A', 'B', 'C'),
34      'Base+Skill': ('A', 'B', 'C', 'D'),
35      'Full-Skill': ('A', 'B', 'C', 'E'),
36      'Full': ('A', 'B', 'C', 'D', 'E'),
37  }
38  CONFIG_ORDER = list[str](ABLATION_CONFIGS)
39  NO_CAUSAL_NOTE = '模型关联与预测贡献解释'
40  SKILL_INCREMENT_PAIRS = [('Base+Skill', 'Base'), ('Full', 'Full-Skill')]

```

图 8.2 特征组消融配置核心代码

图 8.2 展示了五组消融实验的特征组合方式，各组在相同模型参数下完成训练和比较，表 8-1 与图 8.1 的结果均由这些配置得到。

8.2 不同泛化场景下的模型表现

模型在随机划分下的预测表现可能受到训练集与测试集样本构成的影响。Koh 等（2021）在 WILDS 研究中讨论了真实场景下的数据分布偏移及其对模型泛化评估的影响

[22]。结合实习岗位数据的特点，本文分别采用随机划分、按公司分组划分和按发布时间划分三种方式，考察模型在不同样本划分条件下的预测表现。

按公司分组时，以公司实体作为分组单位，同一公司的岗位进入同一数据集，使训练集、验证集和测试集中的公司互不重合；按发布时间划分时，根据岗位发布日期排序，以较早发布的岗位作为训练样本，较晚发布的岗位作为测试样本。两种划分方式的实现分别见图 8.3 和图 8.4。

```

69 def build_company_group_split(model_frame: pd.DataFrame,
70                               random_state: int = SPLIT_RANDOM_STATE) -> pd.DataFrame:
71     """公司实体 Group Split(同一公司的岗位只出现在一个子集中)。"""
72     groups = model_frame['company_entity_id'].fillna('__无实体__').to_numpy()
73     job_ids = model_frame[schema.ID_FIELD].to_numpy()
74     split = np.empty(len(job_ids), dtype=object)
75     holder = GroupShuffleSplit(n_splits=1, test_size=SPLIT_RATIOS[1] + SPLIT_RATIOS[2],
76                               random_state=random_state)
77     train_index, rest_index = next(holder.split(job_ids.reshape(-1, 1), groups=groups))
78     split[train_index] = 'train'
79     holder2 = GroupShuffleSplit(
80         n_splits=1, test_size=SPLIT_RATIOS[2] / (SPLIT_RATIOS[1] + SPLIT_RATIOS[2]),
81         random_state=random_state)
82     valid_rel, test_rel = next(holder2.split(job_ids[rest_index].reshape(-1, 1),
83                                              groups=groups[rest_index]))
84     split[rest_index[valid_rel]] = 'validation'
85     split[rest_index[test_rel]] = 'test'
86     return pd.DataFrame({schema.ID_FIELD: job_ids, 'company_group_split': split,
87                          'company_entity_id': groups})

```

图 8.3 公司分组划分核心代码

图 8.3 以公司实体为分组变量完成训练集、验证集和测试集划分，使不同数据集中的公司互不重合，用于比较模型面对不同公司岗位时的预测表现。

```

945 frame = model_frame.assign(_business_date=axis.dt.normalize().to_numpy())
946 date_counts = frame.groupby('_business_date').size().sort_index()
947 cumulative = date_counts.cumsum()
948 total = int(cumulative.iloc[-1])
949 dates = cumulative.index
950 index1 = min(max(int(np.searchsorted(cumulative.to_numpy(), 0.70 * total, side='left')), 1),
951             len(dates) - 2)
952 index2 = min(max(int(np.searchsorted(cumulative.to_numpy(), 0.85 * total, side='left')),
953             index1 + 1), len(dates) - 1)
954 train_dates, valid_dates, test_dates = dates[:index1], dates[index1:index2], dates[index2:]
955 values = frame['_business_date'].to_numpy()
956 labels = np.empty(len(frame), dtype=object)
957 labels[np.isin(values, train_dates.to_numpy())] = 'train'
958 labels[np.isin(values, valid_dates.to_numpy())] = 'validation'
959 labels[np.isin(values, test_dates.to_numpy())] = 'test'
960 frame['temporal_split'] = labels

```

图 8.4 发布时间排序划分核心代码

图 8.4 根据岗位发布日期顺序确定训练、验证和测试区间，使数据集按照发布时间形

成先后关系，用于比较不同发布时间区间之间的预测结果。

8.2.1 随机划分

随机划分下，仅使用训练集拟合模型时，测试集 MAE 为 36.00 元/天，RMSE 为 66.30 元/天， R^2 为 0.563。将训练集与验证集合并重新训练后，测试集 MAE 为 35.48 元/天，RMSE 为 64.81 元/天， R^2 为 0.582。

LightGBM 与 CatBoost 是候选模型中表现较好的两种梯度提升模型。为比较两者在相同测试岗位上的预测差异，计算 2,233 个测试岗位的逐岗位绝对误差差值，结果见图 8.5。




图 8.5 LightGBM 与 CatBoost 配对误差

LightGBM 与 CatBoost 在同一测试集上的 MAE 分别为 35.4760 元/天和 36.3281 元/天，配对差值为 -0.8521 元/天，95% Bootstrap 区间跨 0；LightGBM 误差更小的岗位占 53.52%。两种梯度提升模型性能接近，LightGBM 依据预先设定的验证集 MAE 规则作为主模型。

8.2.2 按公司分组划分

按公司分组后，训练集、验证集和测试集分别包含 10,521、2,674 和 1,688 个岗位，测试集覆盖 526 家公司。测试集 MAE 为 51.98 元/天，RMSE 为 103.57 元/天， R^2 为 0.136，预测误差明显高于随机划分。

为观察公司分组结果在不同随机划分下的变化，对公司分组重复实施五次，测试误差分布见图 8.6。




图 8.6 公司分组下的测试误差

图 8.6 中，五次公司分组的测试 MAE 分别为 51.98、81.46、38.83、49.44 和 45.74 元/天，均值为 53.49 元/天，标准差为 16.40 元/天。不同公司集合之间的预测误差变化较大，公司所属行业、规模、认证情况以及岗位结构等信息对薪资预测具有较强影响。

8.2.3 按发布时间划分的泛化检验

按发布时间划分后，测试集 MAE 为 31.72 元/天，RMSE 为 47.62 元/天， R^2 为 0.656。该划分下的测试误差低于随机划分，但训练集和测试集的样本构成也发生了相应变化。

比较两个时间区间可以发现，发布时间位置、技能数量、岗位描述长度和一线城市占比等特征均存在差异，测试集的薪资中位数也有所提高。因此，该结果体现了样本发布时间分布与岗位结构共同变化时的预测表现。

三种数据划分方式的样本规模和测试结果汇总见表 8-2。

表 8-2 不同泛化场景的预测表现

划分方式	训练集 n	验证集 n	测试集 n	测试集 MAE	测试集 RMSE	测试集 R^2	说明
随机划分	10,418	2,232	2,233	36.00	66.30	0.563	固定划分，随机种子 42
公司分组划分	10,521	2,674	1,688	51.98	103.57	0.136	同一公司不跨子集，随机种子 42
按发布时间划分	10,083	2,402	2,398	31.72	47.62	0.656	按发布时间排序，同一天不拆分

表 8-2 显示，公司分组的测试误差最高，随机划分居中，按发布时间划分的误差最低。三种划分方式对应的样本关系不同：随机划分保留了整体样本结构，公司分组扩大了不同企业之间的差异，按发布时间划分则反映不同发布时间区间之间的岗位组成变化。

8.3 其他稳健性检验

为比较薪资极端值处理、预测目标调整以及随机种子变化对模型结果的影响，分别使用原始薪资、1%~99% 分位截断后的薪资、薪资下限和薪资上限进行建模，并比较不同随机种子下的 SHAP 特征排序。各项结果见表 8-3。

表 8-3 预测结果稳健性检查

检验设置	MAE	RMSE	R^2	结论
原始薪资（基准）	36.00	66.30	0.563	基准结果
薪资缩尾（1%~99%）	34.90	68.22	0.537	MAE 小幅下降
薪资下限	40.77	74.37	0.450	预测误差增大
薪资上限	47.69	74.07	0.454	预测误差增大

表 8-3 显示，采用 1%~99%分位截断处理后，模型 MAE 由 36.00 元/天下降至 34.90 元/天，而 RMSE 由 66.30 元/天上升至 68.22 元/天， R^2 由 0.563 下降至 0.537。薪资缩尾对不同评价指标的影响并不一致，平均绝对误差有所下降，但较大预测偏差及整体拟合程度未同步改善。分别以薪资下限和薪资上限为预测目标时，MAE 增至 40.77 元/天和 47.69 元/天，说明预测目标的定义会影响模型误差水平。

不同随机种子下得到的主要 SHAP 特征排序相关系数分别为 0.908 和 0.883，排名靠前的特征整体保持相近位置。薪资极端值处理和目标变量定义会改变具体评价指标，但主要特征的相对重要性没有发生明显变化。

8.4 SHAP 模型解释

采用 TreeSHAP 对 LightGBM 在 2,233 个测试岗位上的预测结果进行解释。对于单个岗位，每个特征的 SHAP 值表示该特征相对于模型基准预测值带来的增减贡献，所有特征贡献之和与最终预测结果相对应。具体计算过程见图 8.7。

```

124 def tree_shap_values(model, matrix) -> np.ndarray:
125     """LightGBM 原生 TreeSHAP(pred_contrib)：返回 (n, n_features) 的 SHAP 矩阵。
126
127     注意：当输入为稀疏矩阵时 LightGBM 会返回**稀疏**贡献矩阵（形状 n × (特征数 + 1)，
128     最后一列为基准值 base value），此处统一转为稠密并去掉基准值列。
129     """
130     contrib = model.predict(matrix, pred_contrib=True)
131     if hasattr(contrib, 'toarray'):
132         contrib = contrib.toarray()
133     contrib = np.asarray(contrib, dtype='float64')
134     if contrib.ndim == 1:
135         contrib = contrib.reshape(len(matrix), -1)
136     return contrib[:, :-1]
```

图 8.7 TreeSHAP 贡献提取

TreeSHAP 分解结果与模型预测值之间的最大加性误差为 1.66×10^{-10} 。在获得岗位级 SHAP 值后，进一步计算所有特征的平均绝对 SHAP 值，并针对技能变量分别统计技能出现和未出现时的平均贡献。技能 SHAP 的统计过程见图 8.8。

```

206 for position, skill in enumerate(skill_names):
207     column = int(positions[position])
208     values = shap_matrix[:, column]
209     present = presence[:, column] > 0 if presence_matrix is not None \
210         else np.zeros(len(values), dtype=bool)
211     present_values = values[present]
212     absent_values = values[~present]
213     jobs = int(frequency.get(skill, 0))
214     mean_value = float(values.mean())
215     mean_present = float(present_values.mean()) if present_values.size else 0.0
216     rows.append({
217         '技能': skill,
218         '岗位数': jobs,
219         'model_job_count': jobs,
220         '岗位频率': round(jobs / denominator, 6) if denominator else 0.0,
221         'model_job_frequency': round(jobs / denominator, 6) if denominator else 0.0,
222         'test_present_n': int(present.sum()),
223         'test_absent_n': int((~present).sum()),
224         'mean_abs_SHAP': round(float(np.abs(values).mean()), 6),
225         'mean_SHAP': round(mean_value, 6),
226         'mean_abs_SHAP_present': round(float(np.abs(present_values).mean()), 6)
227         if present_values.size else 0.0,
228         'mean_abs_SHAP_absent': round(float(np.abs(absent_values).mean()), 6)
229         if absent_values.size else 0.0,
230         'mean_SHAP_present': round(mean_present, 6),
231         'median_SHAP_present': round(float(np.median(present_values)), 6)

```

图 8.8 技能 SHAP 方向统计

图 8.8 中，技能出现岗位的平均 SHAP 值反映该技能对应的平均预测方向，平均绝对 SHAP 值反映其整体贡献强度。两项指标结合使用，可以区分技能的重要程度和作用方向。

8.4.1 整体特征贡献

对测试集中各特征的 SHAP 值取绝对值后计算平均值，并按照平均绝对 SHAP 值从高到低排序，主要变量的贡献分布见图 8.9。




图 8.9 主模型 SHAP 蜂群图

图 8.9 显示，模型的重要预测信息主要来自公司属性、技能数量、文本语义和部分岗位特征。福利类标签、技术技能数量、文本语义成分以及公司相关变量均出现在较高位置，表明岗位薪资预测同时受到企业背景、技能要求和岗位文本内容的影响。

不同变量的 SHAP 分布方向也存在明显差异，同一特征在不同岗位上的贡献并不完全相同。例如公司属性和岗位方向相关变量在不同样本中的正负贡献分布较宽，而部分技术技能表现出较为集中的正向贡献。模型对薪资的判断由多类特征共同形成。

8.4.2 技能特征的解释强度与方向

为比较具体技能的贡献强度和方向，分别统计技能出现岗位的平均 SHAP 值和平均绝对 SHAP 值。代表性技能的结果见表 8-4。

表 8-4 技能特征 SHAP 值					
技能	建模样本岗位数 (频率)	测试集 命中岗位数	技能存在时 平均 SHAP	平均绝对 SHAP 值	方向 (技能存在时)
机器学习	578 (3.88%)	74	+21.38	1.726	正向预测贡献
强化学习	145 (0.97%)	15	+45.15	0.609	正向预测贡献
Python	1,918 (12.89%)	259	-1.85	0.524	负向预测贡献
C++	583 (3.92%)	80	+4.74	0.365	正向预测贡献
数据分析	2,718 (18.26%)	402	-0.84	0.362	负向预测贡献
Linux	419 (2.82%)	61	+6.26	0.325	正向预测贡献
深度学习	572 (3.84%)	74	+0.72	0.210	正向预测贡献
Java	619 (4.16%)	85	-2.27	0.206	负向预测贡献
项目管理	487 (3.27%)	77	+2.80	0.172	正向预测贡献
NLP	179 (1.20%)	18	+6.35	0.126	正向预测贡献

技能	建模样本岗位数 (频率)	测试集 命中岗位数	技能存在时 平均 SHAP	平均绝对 SHAP 值	方向 (技能存在时)
计算机视觉	295 (1.98%)	40	+3.44	0.124	正向预测贡献
C	446 (3.00%)	65	+1.65	0.106	正向预测贡献
多模态	231 (1.55%)	27	+0.55	0.098	正向预测贡献
大模型	866 (5.82%)	125	+0.81	0.097	正向预测贡献
办公软件	2,591 (17.41%)	361	-0.19	0.081	负向预测贡献

表 8-4 显示，不同技能在模型中的贡献强度和预测方向存在差异。机器学习的平均绝对 SHAP 值为 1.726，在所列技能中最高；强化学习为 0.609，Python 为 0.524。按技能出现岗位统计，强化学习和机器学习的平均 SHAP 值分别为 45.15 和 21.38，表现为正向预测贡献；Python 的平均 SHAP 值为-1.85，表现为负向预测贡献。技能出现时的平均预测方向与其整体贡献强度存在差异，需要结合两项指标判断技能变量在模型中的作用。

从覆盖规模与模型贡献的关系来看，高频技能并不必然具有较高的薪资区分能力。Python、数据分析和办公软件覆盖岗位较多，其作用更接近普遍性技能要求；机器学习、深度学习以及部分开发技能虽然覆盖范围较小，但在不同岗位薪资水平之间具有更明显的区分作用。技能变量的平均绝对 SHAP 值排序见图 8.10。




图 8.10 技能特征 SHAP Top20

图 8.10 显示，机器学习在技能变量中的平均绝对 SHAP 值最高，深度学习、Python、C++、数据分析和 Linux 等技能随后。部分技能的平均预测方向与其覆盖规模并不一致，反映出技能频率与薪资区分能力属于两个不同维度。

福利标签之间存在较强的共现现象，为进一步比较整组福利信息与单个标签对模型预测结果的影响，固定模型和测试集，分别对全部福利标签及代表性单标签进行 200 次

置换，并记录相对于基准模型的 MAE 增量，结果见图 8.11。




图 8.11 福利标签置换的 MAE 增量

图 8.11 显示，整体福利标签组置换后，MAE 平均增加 14.15 元/天；免费健身设施单独置换后增加 12.25 元/天，节日礼品增加约 0.75 元/天，就近租房补贴、餐饮和弹性工作制的单独置换增量接近 0。免费健身设施、就近租房补贴和餐饮在测试集中有 123 个共同命中岗位，三项标签的取值完全一致。由此可见，多个福利标签集中出现在相同岗位中，组合信息对模型预测的影响明显高于多数单个标签。

8.5 本章小结

特征组消融结果表明，岗位基础、地域和公司属性提供了较多薪资预测信息，技能、文本语义和发布时间位置特征对整体 MAE 的改善幅度相对有限。不同数据划分中，公司分组的预测误差最高，五次分组的平均 MAE 为 53.49 元/天，表明不同企业之间的岗位结构和薪资差异是影响模型表现的重要因素；薪资截断、预测目标和随机种子变化会改变具体评价结果，但主要特征排序整体保持稳定。

SHAP 结果显示，公司属性、岗位类型、技能数量、文本语义和具体技能共同参与薪资预测。机器学习、深度学习以及部分开发技能具有较高的模型贡献，福利标签则表现出明显的组合特征，整组福利信息对预测误差的影响高于多数单个标签。

9 研究结果综合讨论

前述分析显示，岗位方向、企业属性和技能组合共同构成互联网 IT 实习岗位的薪资分层。岗位方向提供了最直观的比较维度，公司认证、行业、城市和公司规模进一步区分同类岗位的薪资分布；技能要求则随岗位任务形成相对稳定的技术栈。预测结果将这些信息置于同一框架中，也反映出跨公司比较需要充分考虑企业背景。以下从学生就业、高校培养和企业招聘三个方面讨论其实际含义。

9.1 岗位薪资结构与就业方向

岗位方向是比较实习机会时最具区分度的信息。人工智能、前端开发、后端开发和移动开发大类的薪资中位数均为 225 元/天，机器学习细分类为 312.5 元/天；运营、客服等职能类岗位多为 150 至 175 元/天。北京、上海和深圳等主要城市之间的中位数差异相对有限，学生在比较岗位时可先结合岗位任务与技术方向判断薪资区间，再将城市作为补充条件。

技能准备应与目标岗位的任务结构同步安排。Python 和 SQL 覆盖多个方向，适合作为基础能力；算法和人工智能岗位集中出现 Python、PyTorch、TensorFlow 和深度学习，前端岗位集中出现 HTML、CSS、JavaScript、Vue 和 React，后端岗位集中出现 Java、MySQL 和 Redis，数据岗位集中出现 SQL、Hive、Spark 和数据分析工具。多模态、C++、C、TensorFlow 和 PyTorch 命中岗位的薪资中位数较高，这些技能同时集中于算法与研发类岗位，求职者应结合岗位细分类而非仅按单一技能判断薪资水平。

企业认证、行业和公司规模为岗位薪资比较提供了另一组信息。两类认证同时具备的岗位中位数为 350 元/天，最佳雇主认证岗位为 200 元/天，无认证和单独行业认证岗位均为 150 元/天。面议岗位在北京、2,000 人以上企业、民营企业以及互联网、游戏、软件行业中的占比更高，比较实习机会时还应同时关注企业背景与薪资披露方式。

9.2 技能需求结构与人才培养

课程建设可围绕高频基础能力与方向技能分层展开。Python、SQL、数据库和数据处理覆盖多个岗位方向，可构成计算机、大数据、人工智能和软件工程等专业的基础训练内容；深度学习、PyTorch、TensorFlow、大模型、Agent 和 AIGC 主要出现在算法与人工智能方向，可结合方向课程和实践项目开展训练。

岗位技术栈为专业方向课程提供了更细的内容组织线索。人工智能和算法方向侧重 Python、PyTorch、TensorFlow 及深度学习，后端方向侧重 Java、MySQL 和 Redis，前端方向侧重 HTML、CSS、JavaScript、Vue 和 React，数据方向侧重 SQL、Hive、Spark 和数据分析工具。较近发布时间队列中，人工智能技能的命中率提高至约 14%~18%，大模型相关要求自 2025 年下半年后出现，课程内容可据此结合岗位变化定期更新。

技术岗位内部的薪资跨度和预测误差也更大。产品和运营岗位的 MAE 约为 30 元/天，人工智能、前端、后端和移动开发岗位为 55 至 60 元/天。就业指导可将岗位细分类、核心技能和企业背景并列呈现，帮助学生形成与岗位任务相匹配的薪资预期。

9.3 企业属性与招聘配置

企业配置实习岗位薪资时，可将岗位任务、行业、公司规模和认证背景作为主要参照。企业认证、所属行业、城市、学历和到岗要求的整体关联强度 ϵ^2 依次为 0.1975、0.1277、0.0899、0.0471 和 0.0171；技术岗位与算法细分类的薪资中位数也高于运营、客服等职能岗位。

职位描述中的技能应围绕实际任务形成明确的组合。算法岗位集中于 Python、PyTorch 和 TensorFlow，前端集中于 HTML、CSS、JavaScript、Vue 和 React，后端集中于 Java、MySQL 和 Redis，数据岗位集中于 SQL、Hive 和 Spark。要求 5 项及以上技能的岗位中位数为 225 元/天，技能数量的效应量为 0.0966；企业在设置技能要求时，应突出岗位任务所需的核心组合，避免仅以技能数量代替岗位能力说明。

随机测试集 MAE 为 35.48 元/天，公司分组五次测试的 MAE 均值为 53.49 元/天，标准差为 16.40 元/天。企业开展市场薪酬校准时，宜优先比较岗位方向、行业、规模和认证背景相近的样本，再结合具体岗位任务确定薪资区间；直接使用跨公司预测结果时，应同时查看误差范围。

10 总结与展望

10.1 主要结论

（1）岗位方向构成互联网 IT 实习薪资结构中最清晰的分层。基于 172,063 条页面记录，研究形成 17,144 个唯一岗位和 14,883 个明确薪资样本；明确薪资岗位的中位数为 175 元/天，四分位距为 90 元。人工智能、前端开发、后端开发和移动开发大类的中位数均为 225 元/天，机器学习细分类为 312.5 元/天，运营和客服等岗位多为 150 至 175 元/天。

（2）企业属性和技能结构与岗位薪资分布存在较强关联。企业认证和所属行业的整体关联强度 ϵ^2 分别为 0.1975 和 0.1277；两类认证同时具备的岗位中位数为 350 元/天。Python 和 SQL 覆盖最广，算法、人工智能、前端、后端和数据岗位呈现不同技术栈。控制岗位细分类后，部分技能的薪资差异收窄，表明技能分布需要结合岗位方向理解。

（3）LightGBM 因验证集 MAE 最低被确定为主模型，在独立测试集上的 MAE 为 35.48 元/天、RMSE 为 64.81 元/天、 R^2 为 0.582，与 CatBoost 表现接近。岗位基础、地域和公司特征构成主要预测信息；公司分组五次测试的 MAE 均值为 53.49 元/天，高于随机划分结果。SHAP 与福利标签置换结果显示，公司标签簇、岗位类型、技能数量和具体技能共同参与模型预测。

10.2 研究不足与展望

研究样本来自实习僧平台“互联网 IT”菜单，岗位、企业与技能结构具有平台和采集时段特征；招聘时间分析中的计划招聘窗口反映页面设定的起止日期。后续可接入更多招聘平台并延长连续采集时间，结合岗位状态变化比较不同渠道、行业周期和技术阶段下的岗位薪资变化。

技能提取以词典和规则匹配为基础，两种文本范围下主要技能的排序相关系数为 0.973，说明主要技能的相对排序较为一致。后续可结合人工标注语料扩展复杂技能表达的识别，并引入企业融资阶段、经营状况和城市生活成本等信息，细化企业与区域特征。

跨公司预测的误差高于随机划分，后续可增加新公司样本和企业动态信息，并按更长的发布时间序列检验模型在新岗位与后续招聘阶段中的表现。

参考文献

- [1] 史珍珍, 曾湘泉. 大数据在劳动力市场研究中的应用与展望[J]. 外国经济与管理, 2016, 38(7): 96-112.
- [2] LENAERTS K, BEBLAVÝ M, FABO B. Prospects for utilisation of non-vacancy Internet data in labour market analysis: an overview[J]. IZA Journal of Labor Economics, 2016, 5: 1.
- [3] BEBLAVÝ M, KUREKOVÁ L M, HAITA C. The surprisingly exclusive nature of medium- and low-skilled jobs: evidence from a Slovak job portal[J]. Personnel Review, 2016, 45(2): 255-273.
- [4] ACEMOGLU D, AUTOR D, HAZELL J, et al. Artificial intelligence and jobs: evidence from online vacancies[J]. Journal of Labor Economics, 2022, 40(S1): S293-S340.
- [5] ALEKSEEVA L, AZAR J, GINÉ M, et al. The demand for AI skills in the labor market[J]. Labour Economics, 2021, 71: 102002.
- [6] KHAOUJA I, KASSOU I, GHOGHO M. A survey on skill identification from online job ads[J]. IEEE Access, 2021, 9: 118134-118153.
- [7] LU Y, TUO H, FAN H, et al. Analyzing the labor market and salary determinants for big data talent based on job advertisements in China[J]. PLoS ONE, 2025, 20(2): e0317189.
- [8] 王辉, 曾湘泉. 劳动力紧缺推升了工资上涨吗? 基于中国劳动力市场大数据的静态均衡检验[J]. 中国人民大学学报, 2017, 31(6): 24-35.
- [9] 孙莹, 章玉婷, 庄福振, 等. 基于集合效用边际贡献学习的可解释薪酬预测算法[J]. 计算机研究与发展, 2024, 61(5): 1276-1289.
- [10] KE G, MENG Q, FINLEY T, et al. LightGBM: a highly efficient gradient boosting decision tree[C]//Advances in Neural Information Processing Systems 30. Red Hook: Curran Associates, 2017: 3146-3154.
- [11] PROKHORENKOVA L, GUSEV G, VOROBEOV A, et al. CatBoost: unbiased boosting with categorical features[C]//Advances in Neural Information Processing Systems 31. Red Hook: Curran Associates, 2018: 6638-6648.
- [12] LUNDBERG S M, LEE S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems 30. Red Hook: Curran Associates, 2017: 4765-4774.
- [13] ZHANG M, JENSEN K N, SONNIKS S D, et al. SkillSpan: hard and soft skill extraction from English job postings[C]//Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies.

Seattle: Association for Computational Linguistics, 2022: 4962-4984.

[14] KRUSKAL W H, WALLIS W A. Use of ranks in one-criterion variance analysis[J]. Journal of the American Statistical Association, 1952, 47(260): 583-621.

[15] MANN H B, WHITNEY D R. On a test of whether one of two random variables is stochastically larger than the other[J]. The Annals of Mathematical Statistics, 1947, 18(1): 50-60.

[16] CLIFF N. Dominance statistics: ordinal analyses to answer ordinal questions[J]. Psychological Bulletin, 1993, 114(3): 494-509.

[17] BENJAMINI Y, HOCHBERG Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing[J]. Journal of the Royal Statistical Society: Series B (Methodological), 1995, 57(1): 289-300.

[18] 史珍珍. 劳动力市场景气对企业岗位空缺持续时间的影响: 基于网络数据的实证研究[J]. 中国人民大学学报, 2017, 31(6): 36-43.

[19] XIAO S, LIU Z, ZHANG P, et al. C-Pack: packed resources for general Chinese embeddings[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2024. DOI: 10.1145/3626772.3657878.

[20] DEERWESTER S, DUMAIS S T, FURNAS G W, et al. Indexing by latent semantic analysis[J]. Journal of the American Society for Information Science, 1990, 41(6): 391-407.

[21] KOENKER R, BASSETT G. Regression quantiles[J]. Econometrica, 1978, 46(1): 33-50.

[22] KOH P W, SAGAWA S, MARKLUND H, et al. WILDS: a benchmark of in-the-wild distribution shifts[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021, 139: 5637-5664.